揭秘NVIDIA大模型推理框架：TensorRT-LLM

DataFunTalk
已认证账号

导读 大家好，我是来自 NVIDIA 的周国峰✦，今天给大家带来的是关于TensorRT-LLM 推理框架方案的介绍。

介绍的主要内容分为如下几部分：

1. TensorRT-LLM✦ 的产品定位

2. TensorRT-LLM 的重要特性

3. TensorRT-LLM 的使用流程

4. TensorRT-LLM 的推理性能

5. TensorRT-LLM 的未来展望

6. 问答环节

分享嘉宾 | 周国峰 NVIDIA DevTech 研发经理

编辑整理 | 周思源✦

内容校对 | 李瑶

出品社区 | DataFun

01TensorRT-LLM 的产品定位

TensorRT-LLM 是 NVIDIA 用于做 LLM（Large Language Model）的可扩展推理方案。该方案是基于 TensorRT 深度学习编译框架来构建、编译并执行计算图，并借鉴了许多 FastTransformer 中高效的 Kernels 实现，然后利用 NCCL 完成设备之间的通讯。考虑到技术的发展和需求的差异，开发者还可以定制算子来满足定制需求，比如基于 cutlass✦ 开发定制 GEMM。TensorRT-LLM 是一款致力于提供高性能并不断完善其实用性的 NVIDIA 官方推理方案✦。

知乎 首发于 人工智能算法实践

WHAT IS TENSORRT-LLM

LLM Inference

NVIDIA solution for scalable LLM Inference. It is built on

- TensorRT to leverage its deep learning compiler for building and executing LLM models/graphs
- FasterTransformer to leverage its optimized kernels for performance
- NCCL for scalable inference, such as TP AllReduce, PP Send&Recv
- Other components for the customizations of LLM inference, such as cutlass

NVIDIA TensorRT-LLM aims to provide the best LLM inference performance on NVIDIA GPU with great flexibility & usability

TensorRT-LLM 已经在 GitHub 上开源，主要分为两个分支，即 Release branch 和 Dev branch。其中 Release branch 每个月更新一次，而在 Dev branch 中则会较为频繁地更新来自官方或社区中的功能，方便开发者体验、评估最新功能。下图展示了 TensorRT-LLM 的框架结构，其中除了绿色 TensorRT 编译部分和一些涉及硬件信息的 kernels 外，其他部分都是开源的。

DataFun.

WHAT IS TENSORRT-LLM

OSS

Open source software (OSS) https://github.com/NVIDIA/TensorRT-LLM

- Stable branch for production
- Dev branch for quick exploring new features in TensorRT-LLM

Open Source

- All Python APIs for model definition and weight loading
- All plugins/kernels except those with a risk of exposing HW information
  - FMHA, Batch Manager
- Pre/post processing, such as tokenizers and samplers

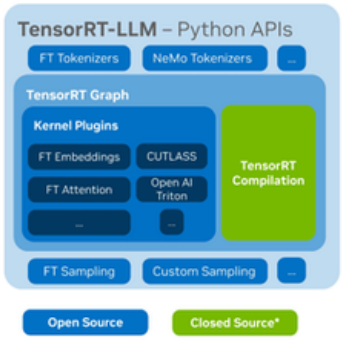

TensorRT-LLM 还提供了类似于 Pytorch 的 API 来降低开发者的学习成本，并提供了许多预定义好的模型供用户使用。

DataFun.

WHAT IS TENSORRT-LLM

Python API

Pytorch-like Python API

- Great usability
  - No need to bother with memory manager, CUDA calls, etc.
  - C++ runtime for performance
- Great modularization for easier extension
  - A lot of predefined models in TensorRT-LLM ready to be deployed for production
  - Users can build customized models easily
    - For performance, may need to write kernels in CUDA
    - NVIDIA can provide supports

```
# Bert.py 50 LoC
# Abstract away the memory & process mgmt.

# Keep representation closer to DL SW
class BertModel(Module)
  def __init__(…)
    self.layers = ModuleList([…])

  def forward (…)
    hidden_states = self.embedding(…)

    for layer in self.layers:
      hidden_states = layer(hidden_states)

    return hidden_states
# Leverage any kernels - no need to write your own
```

知乎 首发于 人工智能算法实践

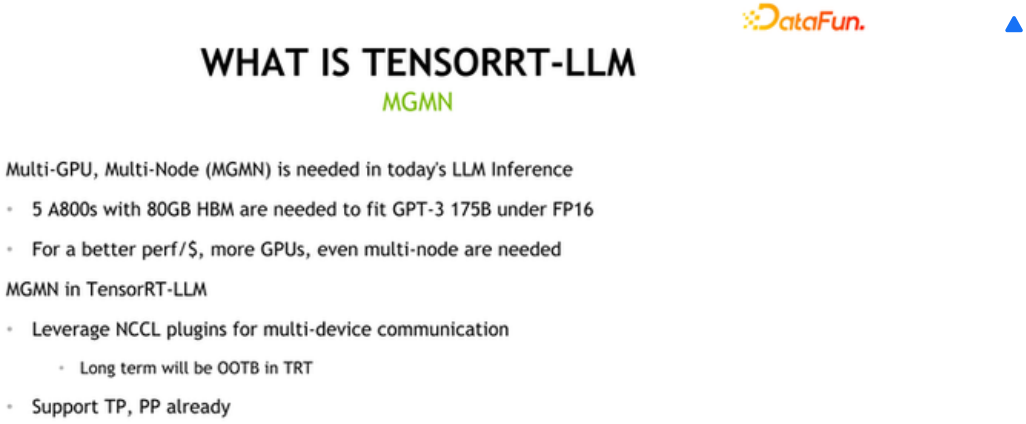

02TensorRT-LLM 的重要特性

TensorRT-LLM 的重要特性之一就是丰富的模型支持。TensorRT-LLM 对主流大语言模型都提供了支持，比如 Qwen（千问）就是由开发者完成的模型适配，并已经纳入官方支持。用户可以很容易地基于这些预定义的模型做扩展或定制。其二就是低精度推理，TensorRT-LLM 默认采用 FP16/BF16 的精度推理，并且可以利用业界的量化方法，使用硬件吞吐更高的低精度推理进一步推升推理性能。

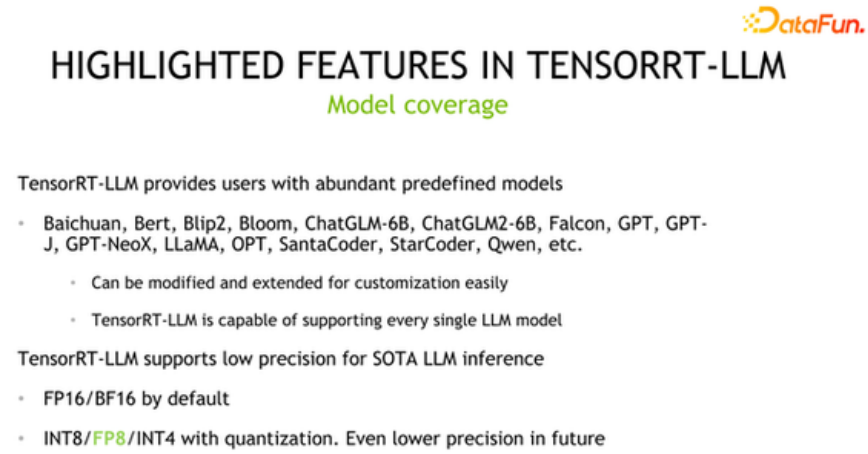

另外一个特性就是 FMHA(fused multi-head attention) kernel 的实现。由于 Transformer 中最为耗时的部分是 self-attention 的计算，因此官方设计了 FMHA 来优化 self-attention 的计算，并提供了累加器分别为 fp16 和 fp32 不同的版本。另外，除了速度上的提升外，对内存的占用也大大降低。我们还提供了基于 flash attention 的实现，可以将 sequence-length 扩展到任意长度。

知乎 首发于 人工智能算法实践

HIGHLIGHTED FEATURES IN TENSORRT-LLM

Flash Attention based FMHA for the Context Phase

FMHA (fused multi-head attention) for the context phase

- Note it is optional as flash attention could potentially affect the accuracy of some models.
- Flags (*--enable-context-fmha/--enable-context-fmha-fp32-acc*) when building engines. Also, it will fall back to unfused MHA when the case is not supported.
- Reduce memory consumption significantly
- No sequence-length limitation with flash attention.

如下为 FMHA 的详细信息，其中 MQA 为 Multi Query Attention，GQA 为 Group Query Attention。

HIGHLIGHTED FEATURES IN TENSORRT-LLM

Flash Attention based FMHA for the Context Phase

FMHA for the context phase

Arch	Flash Attention	Mask Type	Data Type	Head Size	Supported Features
Ampere/Ada (SM 80/86/89)	Yes	Padding Causal SlidingWindowCausal	FP16(FP16 acc) FP16(FP32 acc) BF16 (FP32 acc only)	32/40/64/80/ 128/160/256	MQA/GQA/AliBi
Hopper (SM90)	Yes	Padding Causal SlidingWindowCausal	FP16(FP16 acc) FP16(FP32 acc) BF16 (FP32 acc only)	32/64/128/25 6	MQA/GQA/AliBi

另外一个 Kernel 是 MMHA(Masked Multi-Head Attention)。FMHA 主要用在 context phase 阶段的计算，而 MMHA 主要提供 generation phase 阶段 attention 的加速，并提供了 Volta 和之后架构的支持。相比 FastTransformer 的实现，TensorRT-LLM 有进一步优化，性能提升高达 2x。

HIGHLIGHTED FEATURES IN TENSORRT-LLM

MMHA for the Generation Phase

MMHA (Masked Multi-Head Attention) for the generation phase

- Compute with CUDA cores
- Volta and afterwards archs support
- FP16/BF16/FP32 are supported
- Continue to optimize its performance, up to 2x speedup compared to the one in FasterTransformer

知乎 首发于 人工智能算法实践

而言，这两种量化方式的推理逻辑是相同的。对于 LLM 量化技术，一个重要的特点是算法设计和工程实现的 co-design，即对应量化方法设计之初，就要考虑硬件的特性。否则，有可能达不到预期的推理速度提升。

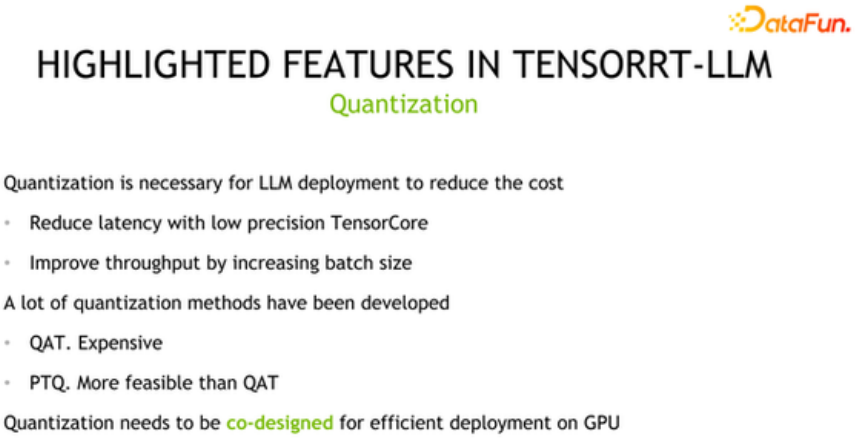

TensorRT 中 PTQ 量化步骤一般分为如下几步，首先对模型做量化，然后对权重和模型转化成 TensorRT-LLM 的表示。对于一些定制化的操作，还需要用户自己编写 kernels。常用的 PTQ 量化方法包括 INT8 weight-only、SmoothQuant、GPTQ 和 AWQ，这些方法都是典型的 co-design 的方法。

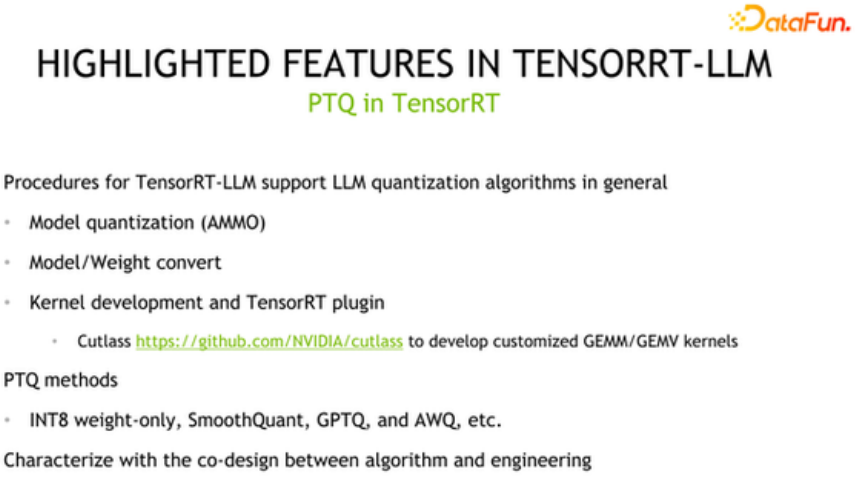

INT8 weight-only 直接把权重量化到 INT8，但是激活值还是保持为 FP16。该方法的好处就是模型存储2x减小，加载 weights 的存储带宽减半，达到了提升推理性能的目的。这种方式业界称作 W8A16，即权重为 INT8，激活值为 FP16/BF16——以 INT8 精度存储，以 FP16/BF16 格式计算。该方法直观，不改变 weights，容易实现，具有较好的泛化性能。

知乎 首发于 人工智能算法实践

HIGHLIGHTED FEATURES IN TENSORRT-LLM

INT8 weight-only

INT8 weight-only

- Quantize weights only to INT8, aka W8A16
- Storage in INT8, compute in fp16/bf16
- 2x reduction in weight storage
  - Few memory traffics
  - High throughput with large batch sizes
- Straightforward and easy to be implemented
- Good generalization ability

第二个量化方法是 SmoothQuant，该方法是 NVIDIA 和社区联合设计的。它观察到权重通常服从高斯分布+，容易量化，但是激活值存在离群点，量化比特位利用不高。

HIGHLIGHTED FEATURES IN TENSORRT-LLM

SmoothQuant

SmoothQuant (Reference)

- Observation: easy to quantize weights, but hard to quantize activations with outliers
- SmoothQuant offline migrates the quantization difficulty from activations to weights

$$\mathbf{Y} = (\mathbf{X}\text{diag}(\mathbf{s})^{-1}) \cdot (\text{diag}(\mathbf{s})\mathbf{W}) = \hat{\mathbf{X}}\hat{\mathbf{W}}$$

  - Step 1. smooth activations X by dividing s>1 and anti-smooth weights by multiplying s to make the formula mathematically equal to XW
  - Step 2. quantize both smoothed activations and weights. W8A8

SmoothQuant 通过先对激活值做平滑操作即除以一个scale将对应分布进行压缩，同时为了保证等价性，需要对权重乘以相同的 scale。之后，权重和激活都可以量化。对应的存储和计算精度都可以是 INT8 或者 FP8，可以利用 INT8 或者 FP8 的 TensorCore 进行计算。在实现细节上，权重支持 Per-tensor 和 Per-channel 的量化，激活值支持 Per-tensor 和 Per-token+ 的量化。

HIGHLIGHTED FEATURES IN TENSORRT-LLM

SmoothQuant

Smooth

- S is a per-channel smoothing factor (vector of size C_input)
- Smooth is performed offline

Quantization

- Per-tensor or per-channel for weights
- Per-tensor or per-token (also outer dimension of GEMM) for activation

SmoothQuant is a typical algorithm of HW&SW co-design

- Efficient to be implemented on GPU

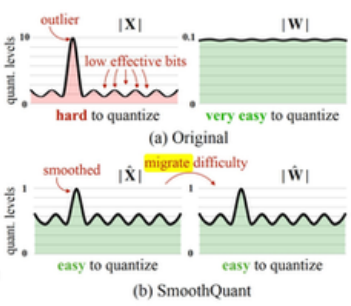

知乎 首发于 人工智能算法实践

就比较大，所以作者设计了一些 trick 来降低量化本身的开销，比如 Lazy batch-updates 和以相同顺序量化所有行的权重。GPTQ 还可以与其他方法结合使用如 grouping 策略。并且，针对不同的情况，TensorRT-LLM 提供了不同的实现优化性能。具体地，对 batch size 较小的情况，用 cuda core 实现；相对地，batch size$^+$ 较大时，采用 tensor core 实现。

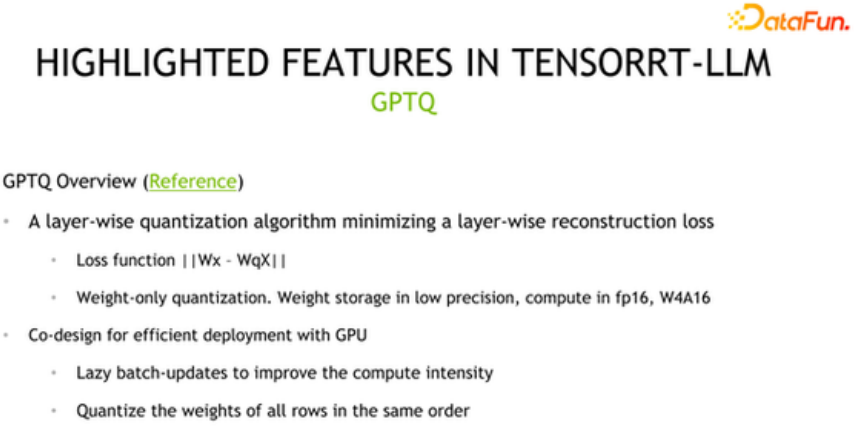

第四种量化方式是 AWQ。该方法认为不是所有权重都是同等重要的，其中只有 0.1%-1% 的权重（salient weights）对模型精度贡献更大，并且这些权重取决于激活值分布而不是权重分布。该方法的量化过程类似于 SmoothQuant，差异主要在于 scale 是基于激活值分布计算得到的。

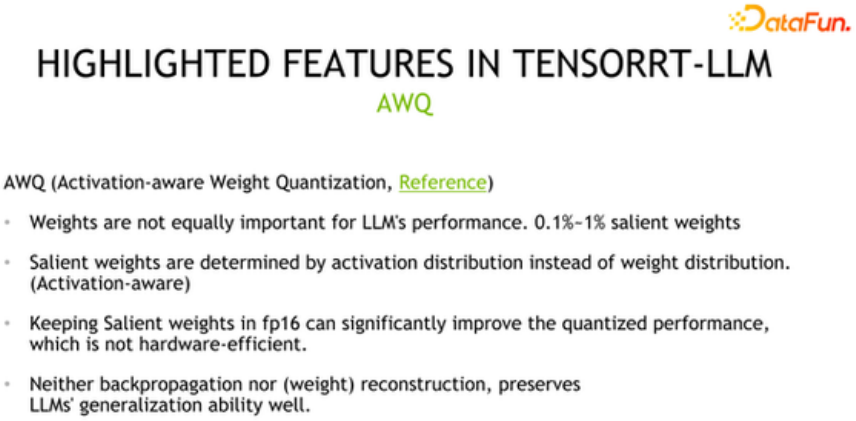

知乎 首发于 人工智能算法实践

HIGHLIGHTED FEATURES IN TENSORRT-LLM

AWQ

AWQ (Activation-aware Weight Quantization)

- Scale up the salient weight before quantization
  - Scalers are determined solely by activation. Similar as the smooth process in SQ, but determine scalers in another way
  - Per-(output) channel scaling
- Grouped quantization along the input channel direction
  - Similar as the GPTQ but with no weight reconstruction
  - Weight-only grouped quantization

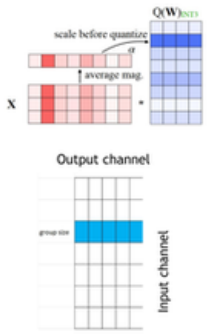

除了量化方式之外，TensorRT-LLM 另外一个提升性能的方式是利用多机多卡推理。在一些场景中，大模型过大无法放在单个 GPU 上推理，或者可以放下但是影响了计算效率，都需要多卡或者多机进行推理。

HIGHLIGHTED FEATURES IN TENSORRT-LLM

MGMN

Cases where MGMN is necessary or beneficial

- The model is too large to fit in a single GPU (e.g., GPT-175B)
  - MGMN reduces the GPU memory footprint because each GPU only stores a part of model weights
- The inference must be performed under latency constraints (e.g., online services)
  - MGMN reduces latencies by splitting the workload to multiple GPUs that are run in parallel
- The goal is to maximize throughput per GPU with no latency constraint
  - The generation phase of the inference is usually memory-bound, which means that the latency grows sub-linearly as the batch size increases
  - Therefore, larger batch size leads to higher throughput
  - MGMN allows using larger batch size per GPU because of the reduced GPU memory footprint

TensorRT-LLM 目前提供了两种并行策略，Tensor Parallelism 和 Pipeline Parallelism。TP 是垂直地分割模型然后将各个部分置于不同的设备上，这样会引入设备之间频繁的数据通讯，一般用于设备之间有高度互联的场景，如 NVLINK。另一种分割方式是横向切分，此时只有一个横前面，对应通信方式是点对点的通信，适合于设备通信带宽较弱的场景。

HIGHLIGHTED FEATURES IN TENSORRT-LLM

TP & PP

TensorRT-LLM implements two types of model parallelism to support MGMN

- Tensor Parallelism (TP)
  - How? Split the model vertically
  - When? Usually, the best choice when the inter-GPU bandwidth is high (e.g., nvlink connection)
- Pipeline Parallelism (PP)
  - How? Split the model horizontally
  - When? Cases when the inter-GPU bandwidth is limited (e.g., no nvlink connection)

知乎 首发于 人工智能算法实践

静态batching的方法，一个batch的时延取决于 sample/request 中输出最长的那个。因此，虽然输出较短的 sample/request 已经结束，但是并未释放计算资源，其时延与输出最长的那个 sample/request 时延相同。In-flight batching 的做法是在已经结束的 sample/request 处插入新的 sample/request。这样，不但减少了单个 sample/request 的延时，避免了资源浪费问题，同时也提升了整个系统的吞吐。

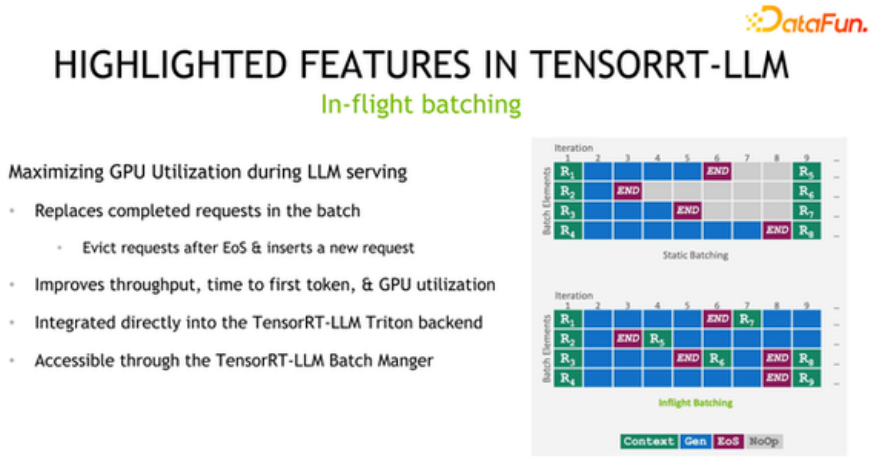

03TensorRT-LLM 的使用流程

TensorRT-LLM 与 TensorRT的 使用方法类似，首先需要获得一个预训练好的模型，然后利用 TensorRT-LLM 提供的 API 对模型计算图进行改写和重建，接着用 TensorRT 进行编译优化，然后保存为序列化的 engine 进行推理部署。

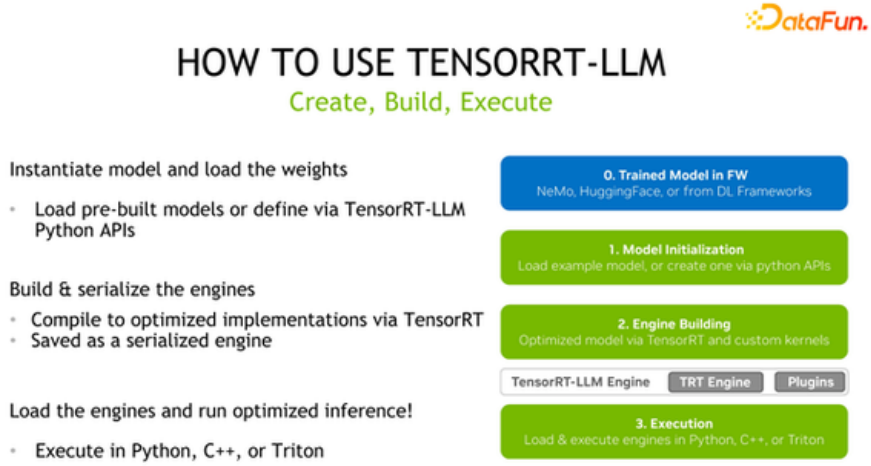

以 Llama 为例，首先安装 TensorRT-LLM，然后下载预训练模型，接着利用 TensorRT-LLM 对模型进行编译，最后进行推理。

知乎 首发于 人工智能算法实践

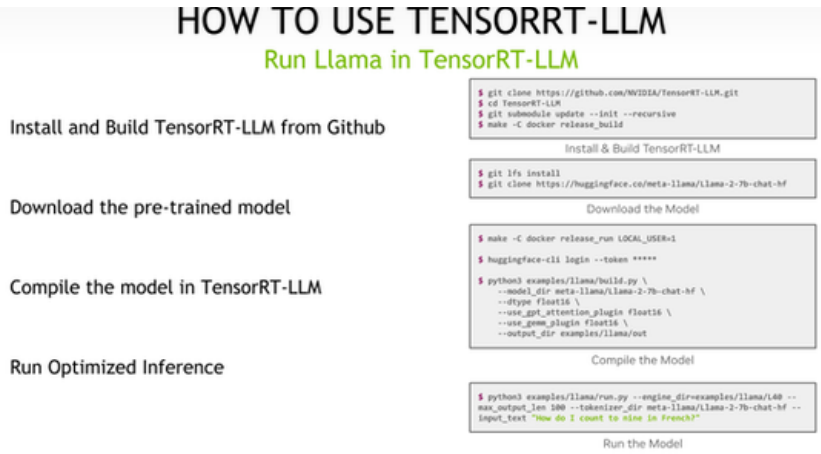

对于模型推理✦的调试，TensorRT-LLM 的调试方式与 TensorRT 一致。由于深度学习编译器，即 TensorRT，提供的优化之一是 layer 融合。因此，如果要输出某层的结果，就需要将对应层标记为输出层，以防止被编译器优化掉，然后与 baseline 进行对比分析。同时，每标记一个新的输出层，都要重新编译 TensorRT 的 engine。

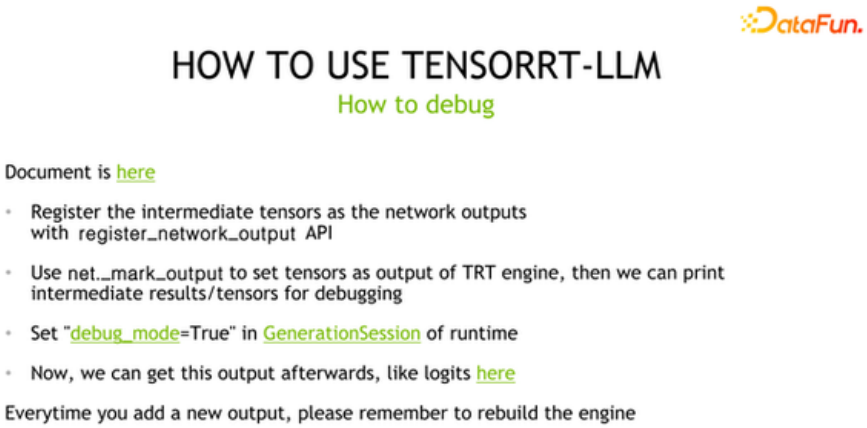

对于自定义的层，TensorRT-LLM 提供了许多 Pytorch-like 算子帮助用户实现功能而不必自己编写 kernel✦。如样例所示，利用 TensorRT-LLM 提供的 API 实现了 rms norm 的逻辑，TensorRT 会自动生成 GPU 上对应的执行代码。

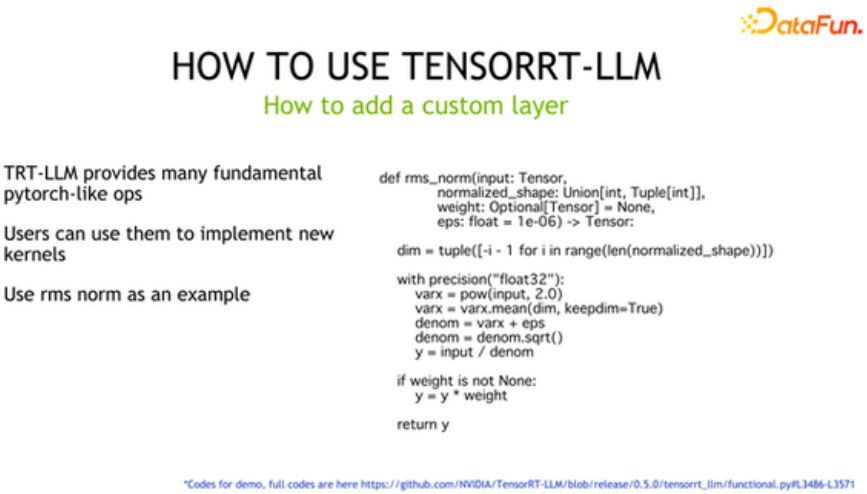

知乎 首发于 人工智能算法实践

SmoothQuant 定制 GEMM 实现并封装成 plugin+ 后，供 TensorRT-LLM 调用的示例代码。

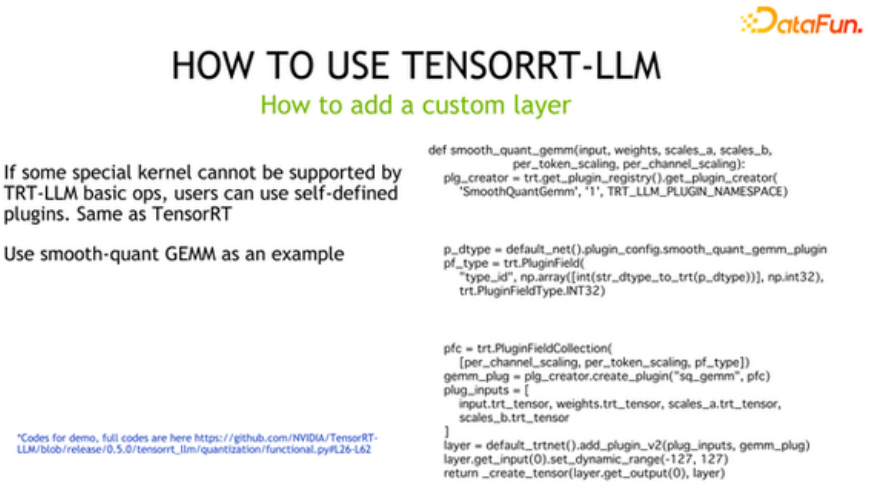

04TensorRT-LLM 的推理性能

关于性能、配置等细节都可以在官网看到，在此不做详细介绍。该产品从立项开始一直与国内很多大厂都有合作。通过反馈，一般情况下，TensorRT-LLM 从性能角度来说是当前最好的方案。由于技术迭代、优化手段、系统优化等众多因素会影响性能，并且变化非常快，这里就不详细展开介绍 TensorRT-LLM 的性能数据。大家如果有兴趣，可以去官方了解细节，这些性能都是可复现的。

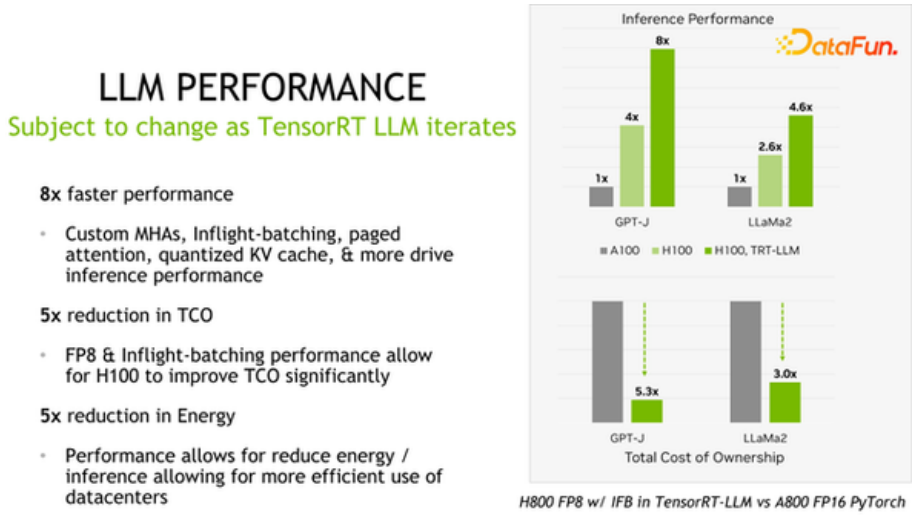

H800 FP8 w/ IFB in TensorRT-LLM vs A800 FP16 PyTorch

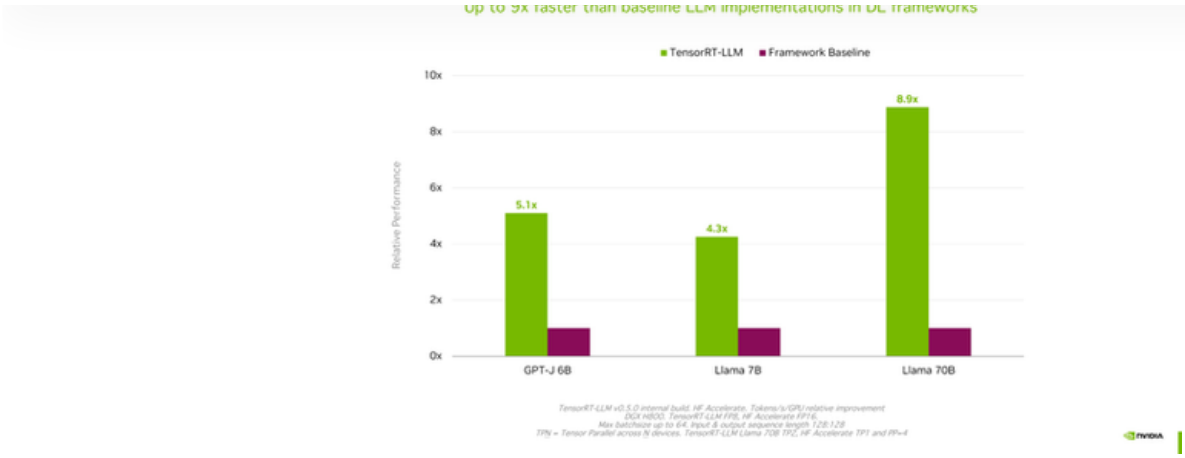

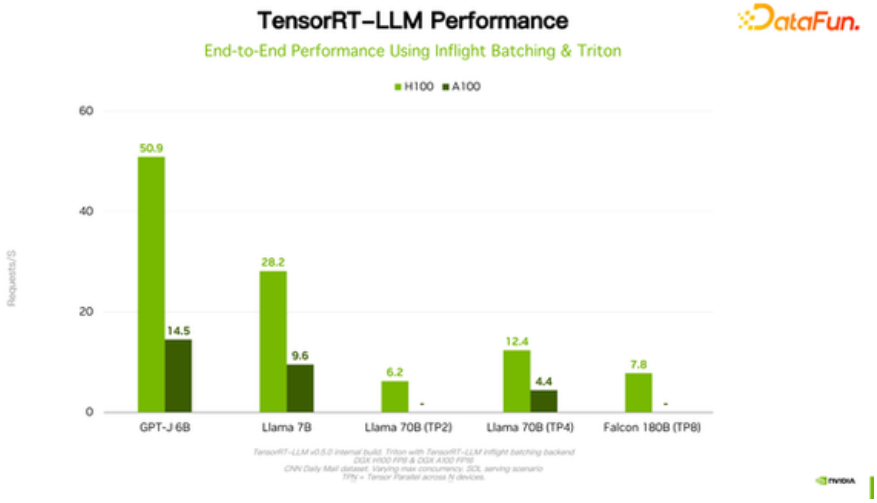

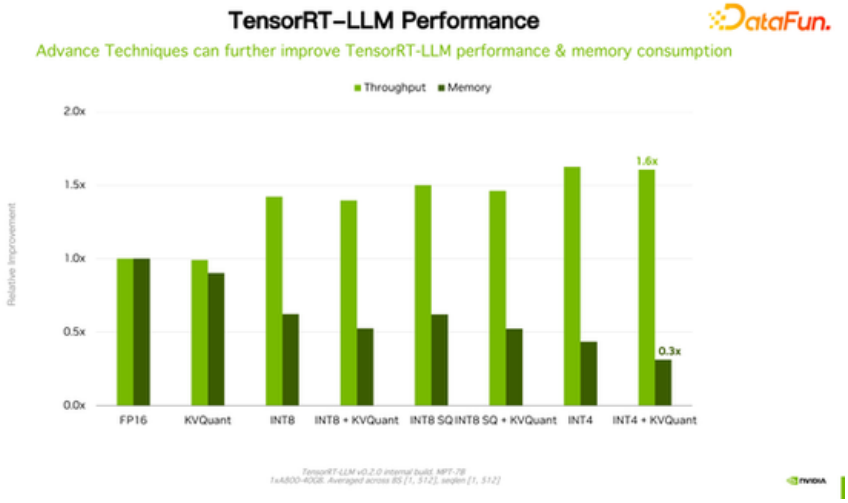

值得一提的是，TensorRT-LLM 跟自己之前的版本比，性能有持续地提升。如上图所示，在 FP16 基础上，采用了 KVQuant 后，速度一致的情况下降低了显存的使用量。使用 INT8，可以看到明显的吞吐的提升，同时显存用量进一步降低。可见，随着 TensorRT-LLM 优化技术的持续演进，性能会有持续地提升。这个趋势会持续保持。

知乎 首发于 人工智能算法实践

LLM 是一个推理成本很高、成本敏感的场景。我们认为，为了实现下一个百倍的加速效果，需要算法和硬件的共同迭代，通过软硬件之间 co-design 来达到这个目标。硬件提供更低精度的量化，而软件角度则利用优化量化、网络剪枝等算法，来进一步提升性能。

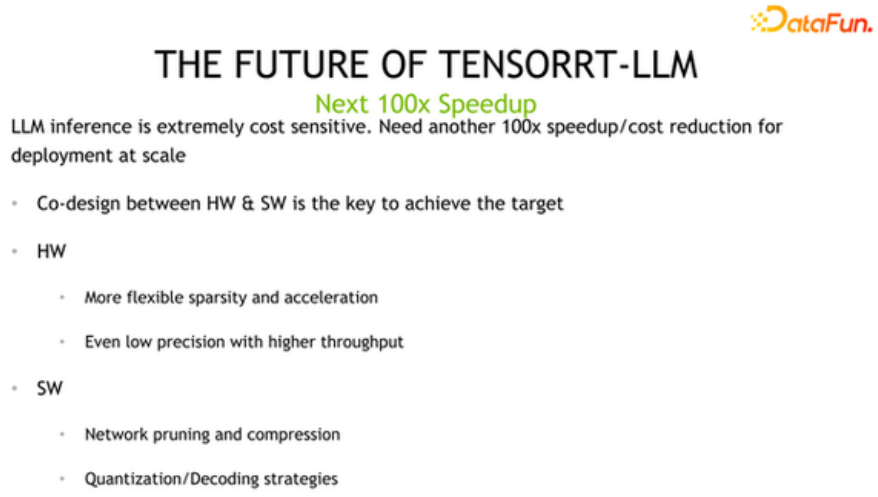

TensorRT-LLM，将来 NVIDIA 会持续致力于提升 TensorRT-LLM 的性能。同时通过开源，收集反馈和意见，提高它的易用性。另外，围绕易用性，会开发、开源更多应用工具，如 Model zone 或者量化工具等，完善与主流框架的兼容性，提供从训练到推理和部署端到端的解决方案。

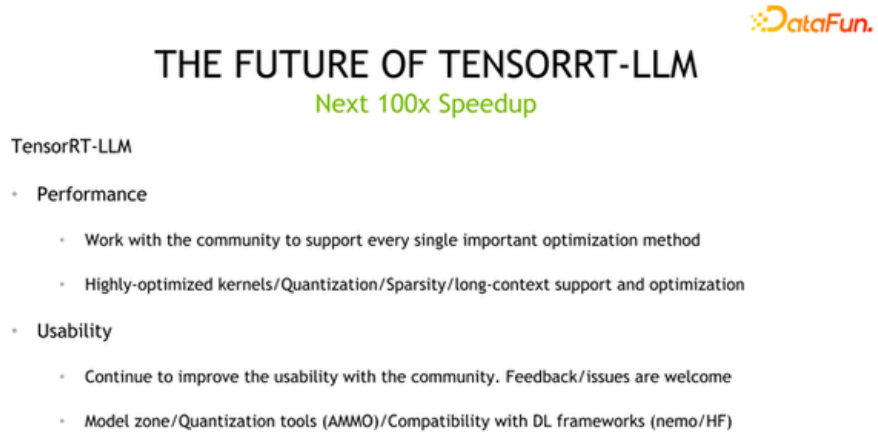

06问答环节

Q1：是否每一次计算输出都要反量化？做量化出现精度溢出怎么办？

A1：目前 TensorRT-LLM 提供了两类方法,即 FP8 和刚才提到的 INT4/INT8 量化方法。低精度如果 INT8 做 GEMM 时，累加器会采用高精度数据类型，如 fp16,甚至 fp32 以防止 overflow。关于反量化，以 fp8 量化为例，TensorRT-LLM 优化计算图时，可能动自动移动反量化结点，合并到其它的操作中达到优化目的。但对于前面介绍的 GPTQ 和 QAT，目前是通过硬编码写在 kernel 中，没有统一量化或反量化节点的处理。

Q2：目前是针对具体模型专门做反量化吗？

A2：目前的量化的确是这样，针对不同的模型做支持。我们有计划做一个更干净的api或者通过配置项的方式来统一支持模型的量化。

A3：因为一些功能未开源，如果是自己的 serving 需要做适配工作，如果是 triton 则是一套完整的方案。

Q4：对于量化校准有几种量化方法，加速比如何？这几种量化方案效果损失有几个点？In-flight branching 中每个 example 的输出长度是不知道的,如何做动态的 batching?

A4：关于量化性能可以私下聊，关于效果，我们只做了基本的验证，确保实现的 kernel 没问题,并不能保证所有量化算法在实际业务中的结果，因为还有些无法控制的因素，比如量化用到的数据集及影响。关于 in-flight batching，是指在 runtime 的时候去检测、判断某个 sample/request 的输出是否结束。如果是，再将其它到达的 requests 插进来，TensorRT-LLM 不会也不能预告预测输出的长度。

Q5：In-flight branching 的 C++ 接口和 python 接口是否会保持一致？TensorRT-LLM 安装成本高，今后是否有改进计划？TensorRT-LLM 会和 VLLM 发展角度有不同吗?

A5：我们会尽量提供 c++ runtime 和 python runtime 一致的接口，已经在规划当中。之前团队的重点在提升性能、完善功能上，以后在易用性方面也会不断改善。这里不好直接跟 vllm 的比较，但是 NVIDIA 会持续加大在 TensorRT-LLM 开发、社区和客户支持的投入，为业界提供最好的 LLM 推理方案。

以上就是本次分享的内容，谢谢大家。

发布于 2024-01-31 18:54 · IP 属地北京

内容所属专栏

人工智能算法实践 订阅专栏

NVIDIA（英伟达） TensorRT LLM

理性发言，友善互动

2 条评论 默认 最新

封翰
Python api文档哪呢?
07-05 · 广东 回复 喜欢

佛系架构师东方锡
tensorRT LLM 支持哪些GPU啊，支持orin吗
03-23 · 江苏 回复 喜欢