

## 如何借助LLM强化推荐系统？中科大深挖图模型潜力



SmartMindAI

专注搜索、广告、推荐、大模型和人工智能最新技术，欢迎关注我

已关注

6 人赞同了该文章

### Introduction

在线招聘推荐旨在根据求职者的偏好和资格，推荐相关的工作机会，从而提高匹配合适职位的机会。随着在线招聘平台的爆炸式增长以及对高效个性化求职体验的需求，构建有效的招聘推荐系统变得至关重要。

鉴于在线招聘数据的稀疏性，行为图谱成为处理互动问题的新工具。在职位推荐中，文本理解和行为建模至关重要，尤其在面对OOS项目这类新需求时。我们利用大型语言模型（LLMs）作为基础框架，通过增强文本表示来提升推荐的准确性和适应性，利用其强大的语义理解和外部知识来克服挑战。

我们的研究为此领域的发展提供了新视角和实用指导。

(1) 不同路径对推荐的影响不均等；(2) 路径顺序对结果稳定性有影响。为应对这些问题，我们创新地提出了路径打乱、自适应路径选择器和混合路径增强策略，以提升推荐的稳定性和个性化。

我们开创性地将经过微调的大型语言模型（GLMs）应用到职位推荐中，利用它们强大的语义理解和广泛的知识，显著提高了匹配的准确性。这是首次这样利用LLMs来强化推荐过程，而非仅限于文本内容。

我们创新性地设计了元路径提示构造器，借助LLMs，这首次实现了对行为图谱的深度理解和解析。这个构造器旨在克服路径依赖的序列输入可能导致的偏见，通过路径增强模块增强了推荐过程的准确性。

### Methodology

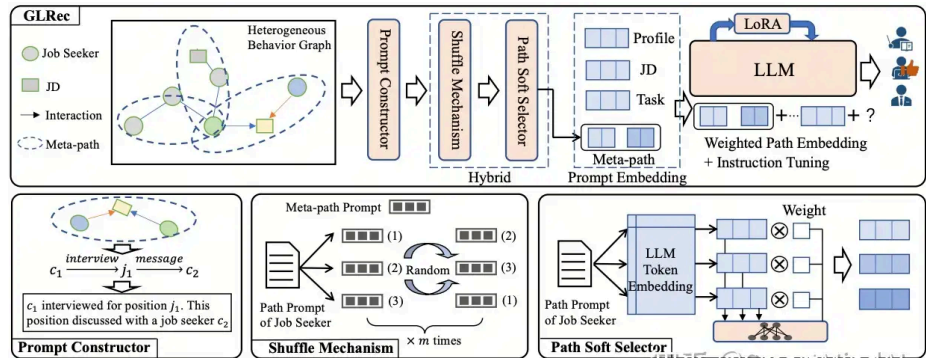


Figure 1: The framework of GLRec for job recommendation.

### Problem Formulation

各自的简历文档和职位要求描述，这些文档是通过文本形式记录的。除此之外，平台还记录了候选人与职位之间互动的历史，表现为双向指向的记录集，如 $\mathcal{A}_{c_i}$ 和 $\mathcal{A}_{j_k}$ ，分别表示候选人 $c_i$ 和雇主 $j_k$ 发起的互动。为了解决这个问题，我们可以采用图论推荐（GLRec）模型，它利用图结构来捕捉候选人和职位之间的复杂关系。具体步骤如下：

构建图：将候选人和职位形成一个图，节点代表候选人和职位，边代表它们的互动历史。

节点表示：对每个节点（候选人和职位），利用LLM（如BERT）对文本进行嵌入，获取其特征表示，既包括原始信息，也考虑了与邻居节点的语义关联。

路径搜索：通过图搜索算法，寻找从候选人到目标职位的路径，路径上的每个节点与目标职位的匹配程度可以通过LLM预测的相似度来评估。

路径评估：根据LLM生成的预测结果，计算不同路径与目标职位的匹配度，这可能包括对简历和职位描述\*的文本相似性分析。

个性化推荐：根据候选人的历史行为和LLM的外部知识，个性化的推荐策略将使推荐更加符合每个候选人的需求和兴趣。

更新和迭代：随着更多的交互数据和用户反馈，模型会持续学习和优化，提高推荐的准确性。

通过这种方式，GLRec能够利用大规模的行为数据和语言模型，有效地预测潜在候选人与特定职位的匹配程度，从而实现在线招聘平台的精准推荐。

## Generative Large Language Models

生成式LLMs如GPT-3、GPT-4能创造贴合语境的文本，通过大量数据训练实现。微调策略如prompt tuning、instruction tuning，用于适配预训练模型至特定领域，均追求相同的自回归损失目标函数如下

$$\mathcal{L}_f = \max_{\Theta} \sum_{(x,y) \in \mathcal{T}} \sum_{t=1}^{|y|} \log(\mathcal{P}_{\Theta}(y_t | x, y_{<t}))$$

在指令调优中，我们设计的指示输入（ $x$ ）如你喜欢这个商品吗？，目标是得到相应的指示输出（ $y$ ，如是）。

参数集 $\Theta$ 代表基础的LLM，而 $\mathcal{T}$ 是我们训练集，包含成千上万的指令输入和期望输出对。训练过程是让LLM理解和遵循这些指示，学会根据输入 $x$ 生成准确的输出 $y$ 。通过反向传播优化 $\Theta$ ，使其能在不同情况下生成与指示相符的文本。当应用于招聘推荐任务时，LLM能根据类似Instruction Input生成符合职位描述的简历内容。这样，模型就能实现个性化的职位推荐，提高推荐的准确性和适应性。

## Task-specific Instruction

我们设计了两点任务测试LLM推荐，参考前人工作：点对点和对职位匹配。设定样本模板，过滤隐私商务信息，定义求职者概况与职位提示。点对点任务预测满意度，指令为：配对任务判断偏好，给定AB两职位，指令为：此设计使LLM适应推荐场景。为稳定训练，在答案后添加职位提示延展预测。接下来，我们将展示如何利用图数据生成行为元路径提示以增强理解。

## Behavior Meta-path Prompt Generation

为了让LLM处理图数据中的交互关系，我们提出元路径提示构造器，该构造器基于异构图（Heterogeneous Graph）概念。异构图包含多元实体（如用户、产品、事件）和不同类型的关联（如购买、社交关系），其复杂性提供了丰富信息。元路径作为节点间关系的抽象表述，如'A-B-C'，通过描述路径来探索特定关联。

通过使用针对异构图的元路径提示，LLM能学习到这些交互模式，从而在推荐任务中更好地理解候选人与职位的关系。这种方法不仅能提升推荐精确度，也展示了LLM在处理复杂网络结构数据上的能力。

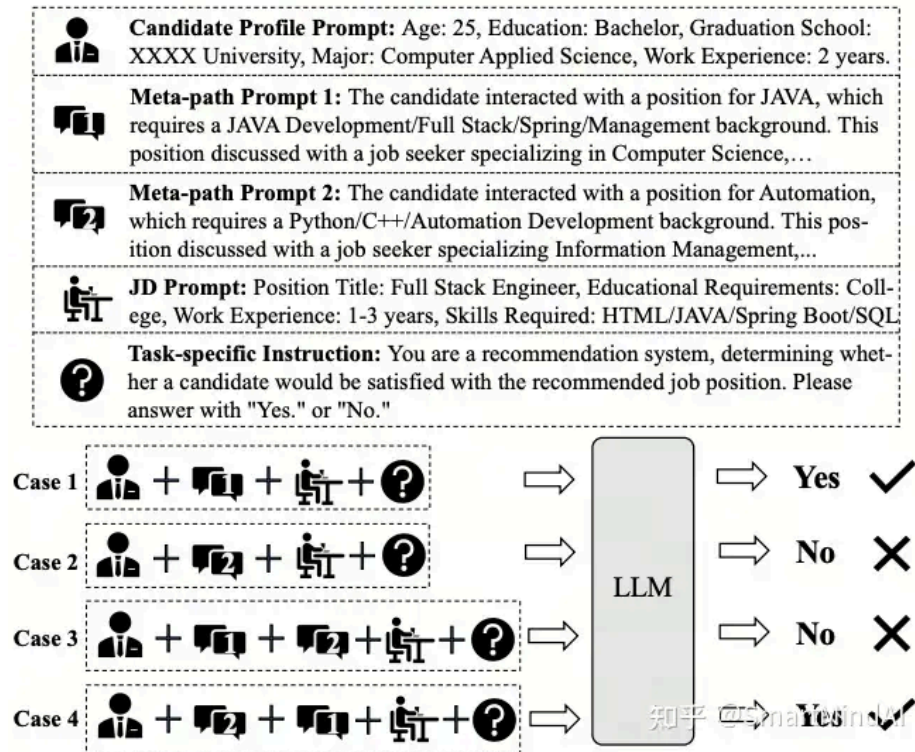
## 知乎

1. 节点 (Nodes) : 这些节点代表不同类型的实体, 如用户、产品、事件等, 每个节点具有特定的类型, 如'User', 'Product'或'Event'。
2. 边 (Edges) : 边连接这些节点, 表示不同类型的关联, 如用户与商品的购买关系、社交网络中的朋友联系等, 边的类型也多样化, 体现了数据的复杂性和丰富性。

这种图形数据模型允许广泛的信息存储和表达, 为处理网络中的复杂交互提供了基础。在接下来的方法中, 我们将利用元路径 (Meta-Paths) 来指导LLM学习和理解这些异构图中的关系。

元路径 (Meta-path  $P$ ) 是定义在异构图 ( $G$ ) 中的一种路径概念, 表示从节点集  $V_1$  演化到节点集  $V_{l+1}$  的路径结构, 通过一系列关系  $E_1, E_2, \dots, E_l$

这些路径描述了节点间通过复合操作 ( $\circ$ ) 的特定组合关系, 如用户-商品购买路径或用户-用户社交路径。元路径在处理异构图数据时至关重要, 因为它能揭示不同实体类型之间的复杂关联, 有助于进行深度理解和挖掘。



异构图相较于同构图在语义上更为多样和复杂。元路径是常用的挖掘及表达其中交互语义的技术。在线招聘中, 求职者与职位间的多种行为互动形成行为图。该行为图是典型的异构图, 节点类型包括求职者 (Candidate)、职位描述 (JD) 等, 边类型涉及消息、面试、匹配等。鉴于行为图中每种边的独特定义语义, 自然考虑将图数据格式元路径转换为大型语言模型可接受的自然语言描述。只需根据路径中出现的边预定义提示模板, 再用简历或职位描述信息填充模板。例如, 给定典型元路径

$$c_1 \xrightarrow{\text{interview}} j_1 \xrightarrow{\text{message}} c_2$$

构建提示模板为: **元路径提示:**  $c_1$  应聘了  $j_1$  职位。该职位与求职者  $c_2$  进行了沟通。节点信息, 即求职者或职位描述, 将填充到元路径提示模板中, 生成数据集中的最终提示数据。此外, 为避免过于相似的元路径导致冗余, 我们定义了一个简单的相似性度量方法如下。

$$S_{i,j} = \frac{|P_i \cap P_j|}{|P_i \cup P_j|}, \quad P_i, P_j \in \Phi_P,$$

在这个上下文中  $\Phi_P$  表示针对候选人样本集的所有潜在路径集合。具体到元路径  $P_i$  和  $P_j$   $|P_i \cap P_j|$  代表它们共享的令牌数量, 即共同存在的部分。  $P_i \cup P_j$  是它们的并集, 涵盖了各自的所有元素。我们通过计算

$$S_{i,j} = |P_i \cap P_j| / (|P_i| + |P_j| - |P_i \cap P_j|)$$

路径中，满足  $\mathcal{S}_{i,j} < \gamma$

以达到路径的独特性和不完全重复。这样设计的目的是在充分利用信息的同时，保持数据集的丰富性和代表性。

## Path Debiasing and Soft Selection

基于序列的元路径提示面对LLM处理行为子图时面临两个难题：

1. 语义解析与路径诠释：LLM需理解串联的节点和边如何构成行为逻辑，需要有能力强解析不同关系 ( $\mathcal{E}_1, \mathcal{E}_2, \dots$ ) 及其间的关联。
2. 顺序依赖与路径多样性：元路径多样性要求模型能识别不同顺序路径对行为含义的影响，而不仅仅是依赖单个路径特征，而是需要结合顺序信息以全面捕获交互模式。

这些挑战凸显了如何利用LLM的优势来解析复杂网络结构数据，以及如何设计适应性强的训练策略以克服这些挑战的重要性。

路径权重在元路径中扮演重要角色，它们不仅定义了节点间的连接顺序，还量化了这些连接的相对价值。这些权重可能是基于数据的统计（如频繁程度或强度）或人工设定，以体现不同行为对求职结果的影响程度。

在处理行为图时，分配不同的权重意味着模型会优先考虑与目标结果关联更紧密的路径。例如，在招聘中，某些路径可能关联直接录用决策（高权重），而其他路径可能代表潜在兴趣或初次接触（低权重）。理解并优化这些权重对于提升模型对候选人行为动态和就业前景的预测准确性至关重要。因此，研究如何有效地学习和调整这些权重是提升模型性能的关键。

路径提示位置的偏斜可能导致模型对路径顺序的过度依赖，从而影响答案的稳定性。在机器学习中，顺序信息有时会对模型学习和预测产生显著影响，尤其当路径权重不均衡时。比如在推荐系统中，错误强调“浏览-点击-购买”路径，可能导致模型**过拟合**购买行为，忽视了用户的浏览意图。

为克服这个问题，需要对路径提示进行平滑处理，减少位置偏斜，或者采用对抗性训练来增强模型对多种路径顺序的理解。总的来说，正确处理路径提示的位置对于保持模型的稳定性和泛化能力至关重要。

在将LLM应用于推荐系统中，处理路径提示位置偏斜的挑战主要体现在两个方面。首先，即使是相似的求职者信息和任务描述，不同的行为元路径（如Case 1和Case 2所示）会导致LLM做出不同决策，表明语义理解与路径解释的复杂性。Path 1因其技术栈的全栈偏好相对Path 2更关键，说明模型对路径顺序的敏感性。

其次，路径提示顺序的微小变化（如Case 3）可能导致模型输出的不稳定性，即使当路径提示顺序颠倒时，模型能恢复正常。这种现象类似于常见的人工智能问题-----任务指令的上下文位置误导，削弱了模型的泛化能力和预测准确性。

因此，优化路径提示的呈现方式，如通过平滑处理减少位置偏斜，或者采用对抗性训练以增强对路径顺序的理解，是提升LLM推荐模型稳定性的关键。

为应对路径提示位置偏斜的问题，我们设计了一个增强模块，包含三个策略来优化LLM在推荐中的表现。首先，采用随机打乱机制（Shuffle Mechanism），在进行SFT训练时，每条包含多条路径的样本都会随机打乱元路径提示，以增加模型学习不同路径组合的语义不变性，提高稳定性和避免冗余信息。其次，实施路径软选择器（Path Soft Selector），通过**启发式方法**选择具有丰富语义的路径，动态调整对每个路径的权重分配。具体做法是计算每个路径的令牌**词嵌入**平均值作为元路径的嵌入  $H_i$ ，这样提高了模型对路径权重的理解和适应性，从而优化推荐准确性。

$$H_i = \frac{1}{|\mathcal{M}_i|} \sum_{t \in \mathcal{M}_i} e_t, \quad i \in \{1, 2, \dots, M\}$$

最后，为了实现这个软选择器，我们采用了SoftSelector方法，它通过动态加权处理每个元路径的嵌入  $H_1, H_2, \dots, H_M$ ，这些嵌入是由路径的平均池化获得的。 $w_i$ 就是对应于路径  $\mathcal{M}_i$  的权重。SoftSelector利用学习算法，如softmax或**注意力机制**，来公平地分配权重，不论路径顺序如何，都能依据实际的语义信息进行调整，从而有效抵消位置偏斜，提升推荐系统的精确度和抗干扰能力。



在这个上下文中，我们引入了一个名为 $W_a$ 的维度为 $d_e$ 的可训练参数 $d_e$ 是每个 $E_i$ 的维度。为防止因值尺度变化引起的训练失效（Training Collapse），我们通过一个名为 $\lambda$ 的控制参数进行调节。 $\lambda$ 位于0到0.5之间，它控制了在新词嵌入时权重的分配。

更新策略如下：原词嵌入 $E_i$ 经过修正后变为 $E'_i$ ，这个过程是通过线性组合完成的，具体公式为：

$$E'_i = \lambda \times W_a \times H_i + (1 - \lambda) \times E_i$$

这里 $E'_i$ 是新的、经过调整的词嵌入，它结合了元路径嵌入 $H_i$ 的动态权重（由 $\lambda$ 乘以 $W_a$ ）和保持原有信息的 $(1 - \lambda) \times E_i$ 。这样的设计旨在保持模型的稳定，防止过激的更新导致泛化能力和抵抗噪声能力下降，从而优化推荐系统的性能。

$$\hat{e}_t = e_t + \lambda \cdot \alpha_i e_t, \quad t \in \mathcal{M}_i$$

相比现有的LLM模型，我们的提示增强机制通过引入短语关注，特别针对路径差异，提供了更精细的处理。这种方法不仅适用于推荐系统，还能广泛应用到其他需要处理路径权重的场景。为解决位置偏斜和训练失效问题，我们还设计了第三个策略，即混合机制（Hybrid Mechanism）。它将随机打乱和路径软选择相结合，形成一个综合策略，旨在同时优化模型的稳定性和泛化能力。在后续的实验，我们将对比这三种策略的效果，以确认它们在提升模型性能方面的有效性。

### LLM Instruction Tuning and Recommendation

我们定义了最终的损失函数 $L_{\text{final}}$ ，它由两部分组成： $L_{\text{auto-regressive}}$ 和路径掩码的加权排名损失。首先 $L_{\text{auto-regressive}}$ 是通过对真实结果和LLM生成的输出进行自回归比较来衡量模型的预测质量。然后 $M_i$ 是用来遮盖或忽略输入提示的掩码，确保模型在处理推荐任务时专注于内容而非提示部分。每个层级的损失  $\text{Loss}_{\text{rank},i}$

是针对秩分解矩阵（用于评估路径相关性）对应的，它反映了路径信息对于预测的重要性。 $N$ 表示模型中Transformer层的个数，表明我们对每个层级的路径处理都是独立且权重不同的。通过这样的组合，我们旨在通过训练过程优化模型，使其既能保持对语义信息的理解，又能避免位置偏斜的影响，从而提高推荐系统的性能和鲁棒性<sup>+</sup>。

$$\mathcal{L}_f = \max_{\Theta_L} \sum_{(x,y) \in \mathcal{T}} \sum_{t=1}^{|y|} \log(P_{\Theta+\Theta_L}(y_t | e_x, y_{<t}))$$

LoRA参数集 $\Theta_L$ 是LoRA（Layer-wise Relevance Propagation）模型特有的。在训练时，我们仅针对这些参数进行更新。与常规推荐系统微调不同，我们使用LLM的嵌入 $e_x$ 替换输入的令牌 $x$ ，因为软选择器改变了提示的嵌入，这一步是关键。在推荐环节，由于经过SFT对齐，模型已学会按照我们设定的目标输出结构生成响应。我们直接从模型在目标位置输出处获取标签概率，比如'Yes./No.'或' $A/B$ '的softmax概率作为预测依据。通过这种方式，我们构建了简洁的预测过程，能有效地利用训练好的模型。

### Experiments

#### Datasets.

我们对RecrX和RecrY两组源于中国大型在线招聘平台的实证数据进行了研究，目的是检验推荐策略。这些数据集来源于在线日志，包含了用户行为的两种类型。

Table 1: The statistics of datasets.

Dataset	# Candidates	# Jobs	# Match	# Interaction
RecrX	12,440	19,318	23,879	54,147
RecrY	18,260	26,576	47,725	119,529

#### Baseline.



度生成个性化推荐。

- 1. HGT：基于图学习，通过在候选人和职位之间传播RoBERTa生成的嵌入，以捕捉潜在的高阶互动关系。
- 2. DPGNN：采用双视角推荐策略，每个候选人和职位各自设有节点，考虑双向选择偏好。
- 3. TALLrec：一个经过LLM微调的高级推荐器，基于LLaMA底座，但我们用BELLE替换，以适应中文环境。

我们的目标是证明GLRec在处理求职推荐任务，特别是在处理稀疏交互数据和理解复杂用户行为时的优越性。

Performance Comparison

Quantitative Comparison.

本研究采用三种实验设置来评估GLRec模型:

Task	Point-wise						Pair-wise	
Split	Random		OOD_position		OOD_JD		Random	
Dataset	RX	RY	RX	RY	RX	RY	RX	RY
RobertaRec	0.710	0.734	0.503	0.528	0.506	0.536	0.727	0.740
HGT	0.744	0.756	0.572	0.595	0.576	0.593	0.747	0.751
DPGNN	0.727	0.743	0.596	0.603	0.588	0.617	0.744	0.756
TALLrec	0.842*	0.829*	0.770*	0.788*	0.766*	0.798*	0.849*	0.825*
GLRec	0.891	0.876	0.810	0.843	0.814	0.852	0.905	0.883
Improve ↑	18.4%	14.1%	25.2%	28.3%	26.4%	29.8%	15.5%	13.2%

实验结果显示，我们的GLRec模型在所有基准方法中表现出最优性能，这得益于其对复杂语义知识的强大理解和适应。特别值得注意的是，即使在不熟悉的OOD\_JD任务上，GLRec仍保持了显著优势，尽管与随机设置相比，成绩略有下降，但远超其他模型，凸显了知识关联在泛化能力上的关键作用。对比HGT和DPGNN这类依赖图结构的模型，它们在处理推荐任务上超越了仅基于RoBERTa的双塔匹配模型（罗伯特+塔Rec），进一步强调了学习关系的必要性。此外，我们的观察指出，点对任务通常比一对一任务更具挑战性，这可能反映了推荐系统需要更精细地理解和预测个体需求。这些发现为招聘推荐领域的深度学习模型设计提供了有价值的方向。

Qualitative Comparison.

Table 3: Some representative cases of our implemented models in the performance comparison experiment. Node 1 and Node 2 denote the nodes in a sampled meta-path of Candidate. RobRec denotes RobertaRec, and GT denotes Ground Truth.

Candidate	Node 1 (Job)	Node 2 (Job Seeker)	Target Job	GT	RobRec	TALLrec	GLRec
Bachelor's degree, Computer Science, 3 years of work experience, skills...	Front-end Developer, Skill requirements: JavaScript / HTML5 / Vue	Bachelor's degree, Computer Applications Technology, Work experience: 2 years, skills...	Java, Qualification: Bachelor's degree, 5-10 years experience, Skill requirements: Java/System Architecture/Database	No	No	No	No
Bachelor's degree, Business Administration, 9 years of work experience, skills...	Project Assistant, Skill requirements: Project Engineering Management	Bachelor's degree, International Economics and Trade, 3 years of work experience, skills...	Project Assistant, Qualification: Bachelor's degree, 3 years or more, Skill requirements: Project Engineering Management	Yes	Yes	Yes	Yes
Bachelor's degree, Computer Applications Tech, 2 years of work experience, skills...	JAVA, Skill requirements: JAVA/Spring/Team Management Experience	Associate's degree, Internet of Things Technology, 4 years of work experience, skills...	Full Stack Engineer, Qualification: Associate's degree, 1-3 years of work experience, Skill requirements: JAVA/Spring/HTML	Yes	No	Yes	Yes
Bachelor's degree, Finance, 10 years of work experience, skills...	Functional Testing, Skill requirements: Software Testing/Requirement Alignment	Bachelor's degree, Financial Engineering, 2 years of work experience, skills...	Test Engineer, Qualification: Bachelor's degree, 3 years of work experience, Skill requirements: Functional Testing/Unit Testing	Yes	No	No	Yes

我们通过表格展示了模型的定性对比结果，显示大多数模型在基本任务上都能准确预测（第一、二行）。然而，第三行突出显示，单纯依赖用户资料并不能充分解决问题。GLRec和TALLrec因为能准确捕捉到用户与JAVA职位在技能需求上的匹配，做出了正确预测（蓝色标记）。有趣的是，尽管TALLrec基于历史行为有时会出错（红色标记），而GLRec通过理解关系，即使面对金融专业背景与目标职位看似不符的情况，也能精确预测（红色标记旁边的解释）。这强调了高阶交互在LLM推荐中的关键作用，以及理解关系对于复杂情境下的有效识别。

原文《Exploring Large Language Model for Graph Data Understanding in Online Job Recommendations》

发布于 2024-05-15 10:48 · IP 属地北京