

港科大2024：LLM赋能基于文本的序列推荐



SmartMindAI

专注搜索、广告、推荐、大模型和人工智能最新技术，欢迎关注我

已关注

9 人赞同了该文章

INTRODUCTION

大型语言模型⁺ (LLMs)，如ChatGPT，在NLP表现出色，引发了推荐系统⁺ (RS) 领域对其潜力的探索。常见的方法是将用户信息和行为数据通过LLM，如TALLRec，以Rec Instruction和Rec Input的形式输入。然而，面对含有大量文本信息的推荐场景，如产品标题或新闻标题，这给LLMs带来了挑战。首先，它们受限于输入长度，可能无法处理丰富文本。其次，Transformer架构的计算复杂度随输入长度增长呈线性，对实时推荐系统资源需求大。最后，长文本可能模糊用户偏好变化，影响推荐效果。

本文提出LLM-TRSR，解决LLMs在处理富文本推荐时的问题。首先，从用户行为序列扩展成适合LLM的长文本⁺。然后，对文本进行分段，确保每个部分都能被模型处理。接着，我们设计了一个LLM集成的摘要器，冻结以保持用户偏好的稳定。然后我们构建了包含用户偏好摘要、近期交互及候选商品信息的提示，通过监督微调优化。同时，通过LoRA-PEFT策略优化内存使用和训练效率。

PROBLEM FORMULATION

在处理富文本序列推荐问题时，我们首先构造用户 u 的交互历史行为序列 \mathcal{S} ，包含用户对商品的点击、购买或阅读等行为，如

$$\mathcal{S} = [I_1, \dots, I_n]$$

其中每个行为 I_i 由多种属性 $A_{i,1}, \dots, A_{i,m}$ 组成，代表不同的行为类型和内容。每种属性 $A_{i,j}$ 是个文本片段，由单词 $w_{i,1}, \dots, w_{i,s_j}$ 构成，共 m 个属性类型和 s_1, \dots, s_m 字的文本长度。目标是利用大型语言模型 (LLMs) 这种强大的文本理解和学习能力，来理解和预测用户潜在的兴趣，从而优化推荐策略。这涉及到如何有效地整合和利用LLMs处理长文本序列，以及如何设计适应LLMs的推荐算法⁺，以提升推荐的准确性和效率。

在富文本序列推荐中，我们的任务是通过大型语言模型 (LLMs) 建立用户 u 对未接触项 I^c 的点击概率模型⁺

$$g_u(I^c) : I^c \mapsto \mathbb{R}$$

这是一个实值映射，表示推荐系统对 I^c 是否值得推荐给用户 u 的预测置信度⁺。这个模型通过分析用户历史行为序列 \mathcal{S} （包括其交互行为和属性文本）以及潜在候选项的文本信息，来量化用户潜在兴趣，从而生成个性化的推荐。模型的目标是通过LLMs的深度理解和学习能力，更准确地估计这个概率，提高推荐的针对性和有效性。

LLM-TRSR框架如下。

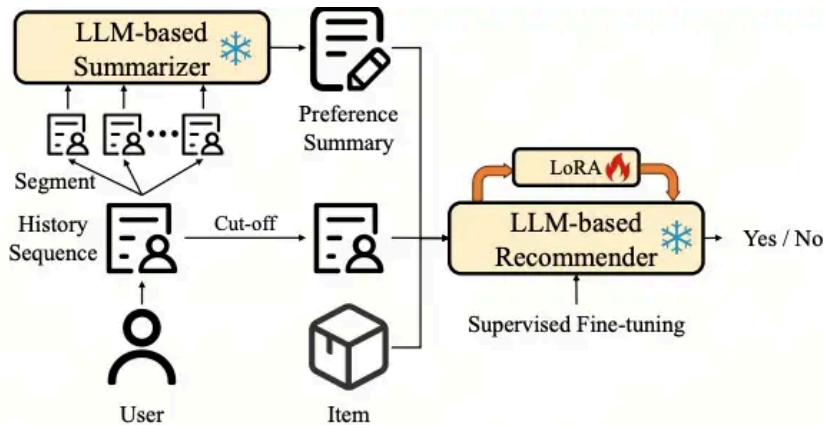


Figure 1: A schematic diagram of our method. The blue frost symbol indicates fixed parameters, while the red flame symbol signifies parameters that are updated during training.

首先，我们通过引入基于LLM的摘要生成器⁺来提取用户偏好的大致内容，包括应用层次摘要（Hierarchical SFT）和循环摘要（Recursive SFT）两种策略。然后，我们将阐述如何利用Low-rank Attention for Fusion of Text (LoRA)的方法对LLMs进行结构化学习，以此训练出基础的推荐LLM。最后，我们将演示如何运用该训练好的模型进行实际的推荐任务，将LLM的预测能力应用于用户行为和文本信息的融合分析中。

Hierarchical LLM-based User Preference Summarization

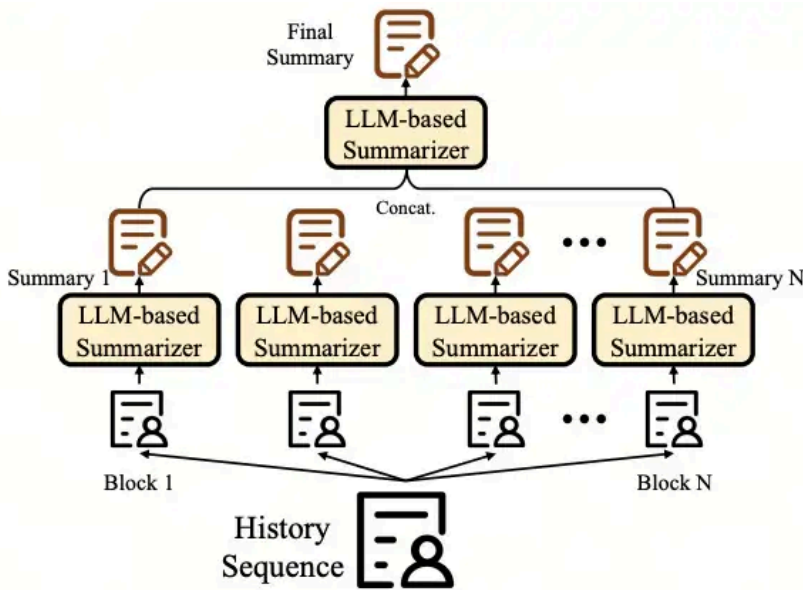


Figure 2: A schematic diagram of the hierarchical summarization paradigm.

1. **数据预处理⁺**：对用户行为序列和属性文本进行词嵌入⁺，将长文本转化为LLM能理解的向量格式。
2. **层次建模**：利用LLM（如Llama）进行层次化处理，通过递归或自注意力，对行为序列逐层提炼关键信息。
3. **特征融合⁺**：结合行为与属性的摘要特征，创建融合的用户表示。
4. **生成用户概述**：用LLM（如LoRA的SFT）生成反映用户兴趣的简洁摘要。
5. **推荐生成**：基于生成的概述，结合其他推荐算法，为用户推荐相关、高质量的项目。
6. **迭代优化**：持续调整和优化推荐策略，以提升推荐效果。

History Sequence Construction and Segmentation

需分割文本，确保每个块仅涉及与有限数量物品相关的部分。

Block Summarization

在层次化摘要范式中，我们通过分块处理长文本，对每个部分进行独立总结，以揭示用户在特定时段的兴趣。基于LLM的零样本生成优势，我们选择了Llama-30b-instruct模型，它在Huggingface Open LLM Leaderboard上表现优异，兼顾了大小和性能。如图所示，我们向模型提供引导性的提示文本，让其对用户购物偏好进行概括。这种方法产出的总结因其针对少量物品，更聚焦于产品细节，如材质。提示文本的调整灵活性使得我们不仅能用于购物，还能适应新闻阅读等其他文本领域的概括需求。

Hierarchical Summarization

在层次化摘要方法中，我们对每个部分进行总结，然后运用LLM进行多层次的概括，通过多摘要输入，生成全面的用户偏好概述。这借鉴了CNN逐层提取特征的思路。

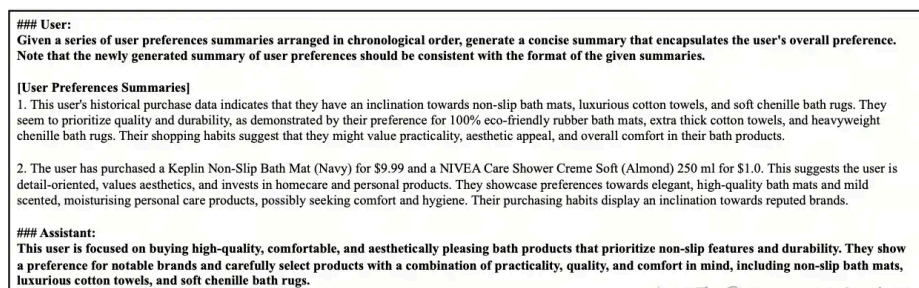


Figure 4: An example of hierarchical summarization.

如图所示，我们设计了指导性的提示，以利于LLM理解并概括。实验显示，多层概括的总结更抽象且有普遍性，能捕捉到整体购物习惯，而非细节。这种方法具有高度的抽象能力和泛化性，即使处理大量商品信息，理论上也能通过增加概括层数来扩展处理能力。

Recurrent LLM-based User Preference Summarization

对于循环摘要（RecursiveSFT）方法。首先，我们将用户行为序列的文本切割成多个独立的部分。然后，我们从第一个区块开始生成摘要。接下来，将前一个摘要和下一个区块的文本输入LLM，使其生成一个反映当前情境的新摘要。

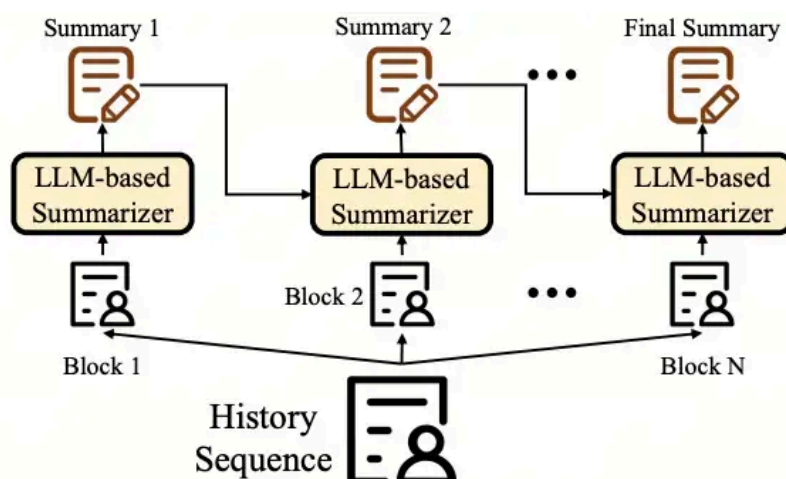


Figure 5: A schematic diagram of the recurrent summarization paradigm.

这个过程会循环进行，直至处理完整个序列，通过这种方式，我们逐步累积并形成用户全面的偏好概述。这种方法利用了RNNs的循环结构，以动态处理和更新信息，确保对整个交互历史的全面理解。

在循环摘要过程中，首先对用户行为序列的首个区块应用了层次化摘要的方法，这是类似的操作。

```
### User:
Given the historical news reading data of a user, including the categories and titles
of the news, craft a concise summary that captures the user's news reading
preferences.

[News Reading Data]
1. Category: travel; SubCategory: travelnews; Title: Southwest Airlines flight diverted:
Man assaulted flyers, police say
2. Category: sports; SubCategory: football_ncaa_videos; Title: Who Won Week 7 in
College Football?
3. Category: video; SubCategory: news; Title: Man testing new tires flees after
crashing into gas station
4. Category: travel; SubCategory: traveltripideas; Title: The Spookiest Place in Every
State
5. Category: foodanddrink; SubCategory: recipes; Title: 3 New Alison Roman Recipes
You'll Be Making for the Rest of Your Life

### Assistant:
This user has a diverse range of news reading preferences, with interests in travel,
sports, video news, and food & drink. Their travel focus includes both travel news
and trip ideas, while in sports they are particularly interested in college football.
They also enjoy video content and exploring new recipes.
```

Figure 6: An example of the first block summarization on the MIND dataset.

如图所示，这个过程在MIND数据集的一个特定用户案例中得以体现，通过展示具体的概括实例。通过这种方式，我们不仅捕获了局部的用户兴趣，还通过多次迭代，构建了用户行为的整体理解。

Recurrent Summarization

在循环摘要阶段，我们基于第一个区块的层次化摘要，继续利用LLM进行迭代和总结。

```
### User:
Given a preference summary of the user, and information related to the historical items the user has purchased, predict whether the user will click on the given
next product. Note that the preference summary captures long-term interests, while the recent items indicate short term interests. Both of them should be
holistically considered for a more comprehensive understanding of user behavior. Please output 'Yes' or 'No'.

[Preference Summary]
The user's preferences lean towards non-slip bath mats, luxurious cotton towels, and soft chenille bath rugs, while also valuing quality and durability in their purchases.
Their recent purchases include a mix of items, reflecting a balance of comfort, practicality, and elegance. In their latest purchase, the user opted for a versatile, stylish
Keplin Non-Slip Bath Mat in Navy color, which is not only water absorbent and quick-drying but also machine washable for a clean and hygienic bathroom. Additionally,
they purchased the NIVEA Care Shower Creme Soft, a moisturizing shower body cream enriched with Almond Oil, Vitamins C and E, nourishing skin and providing a
mild scent. Their preference summary now consists of a diverse range of products, maintaining an ideal balance of comfort, practicality, and elegance.

[Historical Items]
1. Title: Olivia Rocco Bath Mat Plain Super Soft Deep Pile Heavy Weight Micro Bobble Bathmat Bathroom Shower Mat, 50 x 80 cm, Ochre.....
.....
3. Title: NIVEA Care Shower Creme Soft (250 ml) Caring Shower Body Cream Enriched with Almond Oil, Moisturising Shower Gel Body Wash, Skin Moisturiser with
Mild Scent.....

[Next Item]
Title: Creightons Body Bliss Mango & Papaya Bath & Shower (500ml) - Formulated with 90% Naturally Derived Ingredients. 100% Vegan. Cruelty Free. Sustainably
Sourced Fruit Extracts.....

### Assistant:
Yes
```

Figure 8: An example of LLM-based recommendation.

如图所示，针对MIND数据集中的特定用户，我们设计了引导性的提示，以确保LLM能精确理解并生成最终的用户偏好概述。这种方法不仅深化了对局部兴趣的理解，而且通过多次循环，构建了全面的用户行为模式。LLM的输出准确反映了长期和短期的用户兴趣，完成了对行为序列的深度更新。

LLM-based Recommendation

- **推荐指令说明**: 该指令的目标是指导LLM模型在生成用户偏好概述时，不仅要涵盖总体喜好，还要结合用户近期行为，以进行针对性的推荐。推荐过程设计成了一个简单的是或否形式的输出，以指示模型是否应推荐某个项目。
- **偏好摘要** 是从层次化或循环的文本概括技术中衍生，它用来精确反映用户的长期兴趣，通过整合LLM对用户行为序列的全局理解。
- **近期用户行为** 指的是用户最近参与或操作过的商品或服务，体现了他们的即时或短期兴趣。
- **候选商品描述** 包括了所有候选商品的详细文本特征，用于提供给LLM模型参考以进行推荐。

$$\mathcal{L}_{sft} = - \sum_{i=1}^L \log \Pr(v_i | v_{<i})$$

在这个上下文中， v_i 表示提示文本中的第*i*个单词，而*L*是提示文本的实际长度。LLM模型在训练时使用的是基于Next-Token Prediction的策略，它计算每个位置的单词预测概率 $\Pr(v_i | v_{<i})$ ，即根据前一个单词预测下一个单词的可能性。为了实现参数高效的微调（PEFT），我们采用低秩适应（LoRA），这是一种策略来减少需要更新的参数数量，以提升模型在保持性能的同时节省计算资源。

在训练完成后，我们不再依赖明确的是或否标签，而是直接对修改后的提示*P*进行预测。模型会给出用户对推荐项可能采取的是或否行动的概率，如：

$$P_{\text{next-word}} = P(\text{"yes"} | P) \quad \text{或} \quad P_{\text{next-word}} = P(\text{"no"} | P)$$

这些概率反映了模型对用户未来行为的推测，有助于生成更贴合用户当前兴趣的个性化推荐。

$$p_{yes} = \Pr('yes' | P), \quad p_{no} = \Pr('no' | P)$$

在模型验证的最后一步，我们应用softmax函数处理 $P_{\text{next-word}}$ 来量化交互概率。softmax函数将每个概率映射到0到1之间，使得所有概率之和为1，这样我们就得到了用户对每个推荐项实际接受可能性的分布。这个概率越高，意味着用户对推荐项的兴趣程度更强。在实际应用中，根据这个概率，推荐系统会决定是否推荐该商品或服务。

$$p = \frac{\exp(p_{yes})}{\exp(p_{yes}) + \exp(p_{no})}$$

Dataset Description

我们利用了Amazon-M2商品推荐和MIND新闻推荐两套文本序列数据。我们仅考虑那些至少进行了10次且最多不超过25次交互的观测，以确保数据的有效性和代表性。在训练阶段，我们采用了1:1的负样本平衡策略，即每个正样本配对一个负样本，以避免过拟合⁺。而在验证集和测试集上，我们采用了1:20的负样本比例，以获得更广泛的负样本分布，用于评估模型⁺的泛化能力。

Table 1: Statistics of the datasets.

description	Amazon-M2	MIND
# of different attributes	10	4
# of positive samples in the training set	10,000	10,000
# of positive samples in the validation set	1,000	1,000
# of positive samples in the test set	1,000	1,000
Avg. # of historical user behavior sequence	13.16	16.23
Avg. # of tokens corresponding to an item	141.45	40.83

Experimental Settings

Baseline Methods and Evaluation.

实验中，我们对比了基于传统方法的两种基准：内容为基础的推荐（Content-Based Recommendation）和协同过滤⁺（Collaborative Filtering, CF）。前者利用用户过去的购买行为和商品静态属性进行推荐，后者通过用户相似性分析来推荐未被直接消费的商品。我们将这些基线 with LLM驱动模型进行评估，通过精确度、召回率⁺、F1分数等指标来衡量其理解和预测用户兴趣的能力。这样，我们能清晰地展示LLM在处理复杂文本序列数据时的优势。

实验中，我们加入了NCF（Neural Collaborative Filtering，神经协同过滤）这一深度学习的协同过滤模型作为额外的基线。NCF利用max-pooling来简化用户表示，这种方法强调了用户特征的集中概括，有利于捕捉关键信息。我们以此来检验NCF在预测用户兴趣上相对于传统内容和协同过滤方法的优越性。

捉增强了模型对用户兴趣的洞察力，从而提升了推荐的精准度。

除了DIN，我们还引入了几款先进的序列推荐技术作为基线，包括：Seq2Seq、GRU4Rec、BERT4Rec、Transformer-based和DIEN等方法

在实验中，我们不仅采用了传统的基于ID的基线（如DIN, DIEN和CORE），而且采用了经过预训练BERT的文本嵌入，而非单纯基于唯一标识符⁺。我们选择了LLM作为我们的研究模型，利用其强大的语言理解和上下文理解能力，生成更深入且符合用户兴趣的推荐。

在实验中，我们加入了TALLRec，这是一种通过指导优化（Instruction Tuning）利用大型语言模型进行推荐的方法。TALLRec并非简单利用LLM生成推荐，而是通过改变LLM的运行机制以更好地服务于推荐任务。它巧妙利用了LLM强大的语言理解和生成能力，生成个性化的推荐，以提升推荐的精准性和用户满意度。

为了评估各模型的性能，我们采用了Recall@K和Mean Reciprocal Rank (MRR)@K作为评估标准。Recall@K关注前K个推荐中是否能准确找到用户感兴趣项目，即推荐列表中有多少是正确的，以K的值(比如3、5、10)来量化。MRR@K计算的是所有位置的倒数排名平均值，对每个位置，如果预测正确，排名位置的倒数作为得分，通过累积所有位置的倒数来评估排序的准确性。

Implementation Details.

实验在12台配备8个A800 80GB GPU的Linux集群上进行，使用Hugging Face库的Llama-30b-instruct(8位量化版)和Llama-2-7b(BF16格式)作为模型，分别处理摘要生成和推荐任务。我们用PyTorch和TRL库执行SFT步骤。采用LoRA，设定为8级排名，优化器为AdamW，学习率1e-4，批大小1，梯度累积64步。分布式训练依赖Deepspeed，采用ZeRO阶段2。实验参数设定最大令牌长度为2048，每个块项目数为5。

Overall Performance

Table 2: The performance of different models.

	Amazon-M2						MIND					
	Recall			MRR			Recall			MRR		
	@3	@5	@10	@3	@5	@10	@3	@5	@10	@3	@5	@10
NCF	0.8300	0.8830	0.9440	0.7328	0.7448	0.7529	0.7010	0.8030	0.9240	0.5523	0.5759	0.5926
DIN	0.7380	0.8330	0.9240	0.5838	0.6053	0.6174	0.7900	0.8620	0.9330	0.6352	0.6519	0.6616
DIEN	0.7330	0.8170	0.9070	0.5922	0.6114	0.6229	0.7300	0.8200	0.9140	0.6045	0.6251	0.6379
GRU4Rec	0.4420	0.5590	0.7350	0.3355	0.3621	0.3855	0.6650	0.7970	0.9260	0.5305	0.5610	0.5787
NARM	0.8410	0.8860	0.9330	0.7475	0.7577	0.7638	0.5820	0.7330	0.8930	0.4142	0.4489	0.4703
SASRec	0.6550	0.7570	0.9040	0.4938	0.5173	0.5374	0.8420	0.8960	0.9410	0.7447	0.7574	0.7636
CORE	0.5230	0.4632	0.6450	0.4527	0.4632	0.4728	0.5170	0.5580	0.6370	0.4392	0.4488	0.4586
TALLRec	0.8790	0.9050	0.9460	0.8585	0.8644	0.8697	0.8580	0.9020	0.9590	0.7708	0.7807	0.7885
LLM-TRSR-Hierarchical	0.8910	0.9120	0.9490	0.8597	0.8643	0.8693	0.9160	0.9470	0.9750	0.8535	0.8603	0.8611
LLM-TRSR-Recurrent	0.8910	0.9130	0.9570	0.8632	0.8681	0.8737	0.9060	0.9390	0.9840	0.8400	0.8475	0.8534

我们实验结果显示，LLM-TRSR无论在何种评估标准（如Recall@K和MRR@K）下，都能显著优于其他基线方法，这充分展示了它在处理包含大量文本信息的序列推荐任务中的优越性能。这不仅是对模型精准理解用户兴趣的肯定，也体现了其在理解和处理动态变化和顺序信息上的独特能力。同时，它生成的推荐更具人性化，提高了用户满意度。这说明LLM-TRSR在当前任务中具有无可比拟的优势，强化了其在推荐系统领域的有效性。

通过实验，我们证实了基于LLM的推荐技术（LLM-TRSR）在多项评估标准下超越了传统方法，这明确展示了其在处理包含丰富文本信息的序列推荐任务中的强大效能。这种表现不仅证明了LLMs对用户兴趣深度理解和动态变化的出色捕捉，也表明其生成的个性化推荐更贴近用户需求，提升了用户体验。因此，LLM在推荐系统领域的应用潜力巨大，这是其显著超越传统方法的关键所在。

在Amazon-M2数据集上，LLM-TRSR-递归模型的表现优于LLM-TRSR-层次模型⁺，但在MIND数据集上，层次模型却占据优势。这说明针对具体环境，采用适应用户偏好总结的不同策略（如递归和层次）可能具有有效性。递归模型可能擅长捕捉兴趣随时间的逐步演变，而层次模型可能揭示了用户深层次的整体兴趣。这强调了在序列推荐中选择最贴合用户需求的方法至关重要，以确保精准推荐。

原文《Harnessing Large Language Models for Text-Rich Sequential Recommendation》

发布于 2024-04-24 10:33 · IP 属地北京