

阿里巴巴2024：运用大模型（LLM）建模用户阅读流，赋能精准推荐



SmartMindAI

专注搜索、广告、推荐、大模型和人工智能最新技术，欢迎关注我

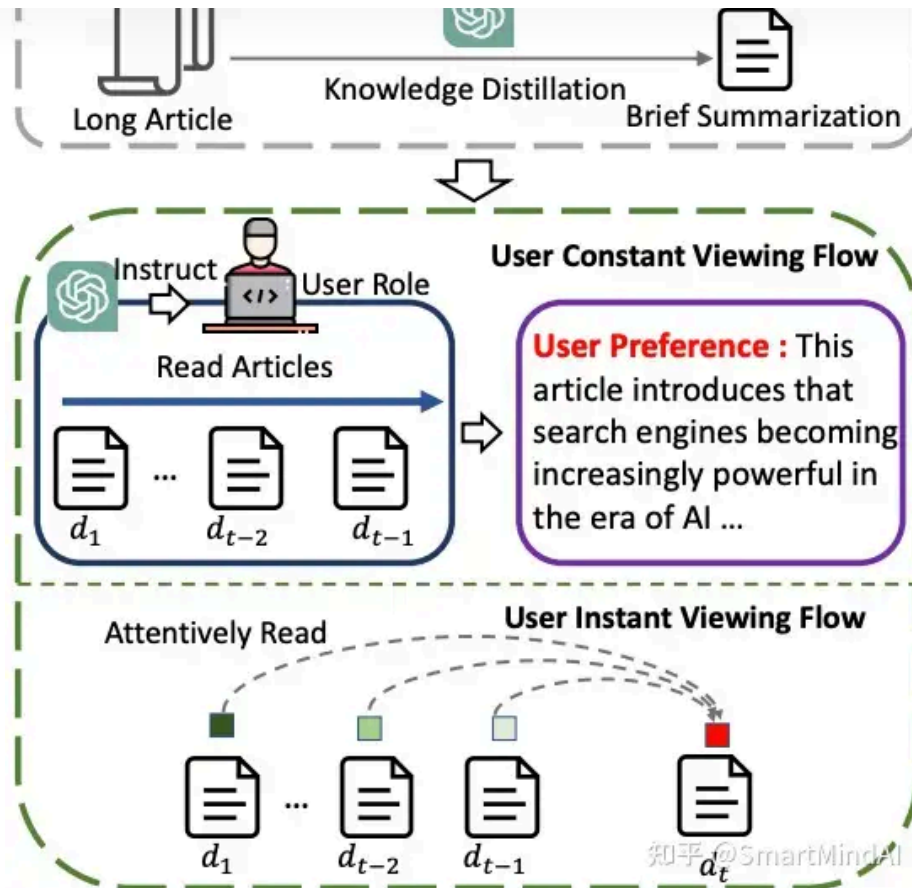
已关注

5 人赞同了该文章

Introduction

在线平台如微软新闻、知乎、CSDN和博客+提供新闻浏览、观点交流和知识学习服务，但面对海量信息，用户常感困扰，需要推荐系统+协助筛选有价值内容。为此，内容推荐系统成为关键，通过学习用户点击行为，为用户提供个性化新闻推荐，以满足其信息需求。这类模型主要基于新闻推荐，通过捕捉用户兴趣偏好来推送相关内容。

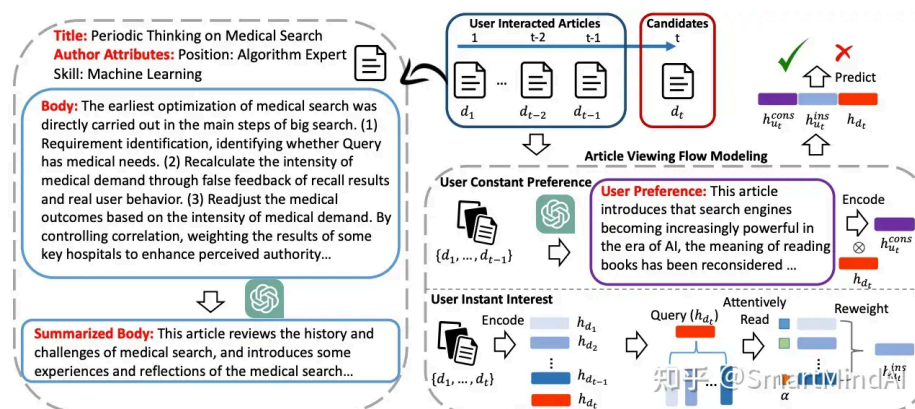
本研究提出用户视角流建模（SINGLE），这是一种针对内容推荐的新方法。通过模拟用户连续和瞬时的浏览行为，SINGLE能更精准地揭示用户兴趣，提取推荐所需的信息。



## Methodology

我们提出用户视角流建模（SINGLE），首先在篇章结构中概述了整体框架。然后，我们深入探讨了SINGLE的两个核心模块-----用户持续浏览流建模和用户即时观看流建模。前者通过分析用户长时间的浏览行为来捕获持久兴趣，后者利用用户点击历史与候选内容的交互来挖掘多角度兴趣。这两种方法结合，旨在构建更为个性化推荐，既能满足用户深层次兴趣，又能确保内容的多样性。

## Framework of SINGLE



如图所示，当用户已查看的内容集合

$$D_{1:t-1} = \{d_1, \dots, d_{t-1}\}$$

给出时，我们的目标是为用户在时间步 $t$ 推荐最符合需求的后续内容 $d_t$ 。在本节，我们将详细阐述如何处理内容的表示和转化过程，以及如何依据用户过去的点击行为来预测下一篇内容。这通常涉及将内容集转化为模型可以理解的向量形式，并通过学习这些交互关系来决定哪些内容最有可能吸引用户。

在这个过程中，我们利用LLMs（如**LLM**）对指示语 **$s$** 和内容 **$b$** 的输入进行计算，以获取其内在意义的表示，即：

$$d_i^{b*} = LLM(instruct_s, d_i^b)$$

这样，我们不仅能够利用LLM的强大抽象能力，还能克服文本长度的限制，从而对内容进行全面深入的理解和推荐，不受具体文本长度的制约。

$$d_i^{b*} = LLM(instruct_s, d_i^t, d_i^b)$$

我们提出User Viewing Flow Modeling (SINGLE)，通过创建内容摘要指令 **$instruct_s$** ，利用LLM生成更简洁的内容表示( $d_i^{b*}$ )，如ATA数据集上，平均长度缩短至260)，替代原文的长篇内容。这样，我们结合LLM的广泛适用性和对长文本的理解能力，以 **$d_i^t$** (标题)、 **$b_i^{b*}$** (摘要)和 **$d_i^a$** (属性)来重构内容表示。这种方法既克服了LLM的长度限制，又保留了内容的关键信息，从而在推荐时提高了精确度和有效性。

### Article Encoding

$$h_{d_i} = f(d_i^a, d_i^t, d_i^{b*}) = w_a \cdot d_i^a + w_t \cdot d_i^t + w_b \cdot d_i^{b*}$$

这里 **$f$** 是融合函数，**权重向量**( $w_a, w_t, w_b$ )根据各部分信息的重要性进行分配。通过这种方式，模型能够综合考虑多维度的特征，以更全面地理解和预测用户对下一篇文章的兴趣。

$$h_{d_i} = h_{d_i}^a; h_{d_i}^t; h_{d_i}^{b*}$$

$$h_{d_i}^t = \text{Linear}(\text{BERT}(d_i^t)); h_{d_i}^{b*} = \text{Linear}(\text{BERT}(d_i^{b*}))$$

在训练过程中，BERT参数保持固定以避免**过拟合**，对内容属性信息使用随机初始化的嵌入表示。然后，我们按顺序合并这些属性特征，形成一个完整的属性特征向量。接下来，我们通过**多层神经网络**处理这个特征，生成最终的属性特征向量 **$h_{d_i}^a$** 。这样做保证了属性信息的有效融合，有助于推荐系统准确理解内容的属性，从而提升推荐的准确性。

### Next Article Prediction

我们采用SINGLE模型，通过分析用户浏览历史中的瞬时兴趣和长期偏好，构建用户表示向量 **$h_{u_t}$** 。然后，利用这个用户表示预测目标内容 **$t$** 在时间 **$t$** 的点击概率，计算公式为：

$$\hat{p}(d_t|u_t) = f_{click}(h_{u_t}, h_{d_t})$$

其中 **$\hat{p}$** 是估计的**点击率**， **$f_{click}$** 是一个**神经网络模型**，结合了用户当前兴趣与长期习惯，能更精确地估计用户对 **$d_t$** 的兴趣，从而提升推荐的精准度。

$$P(y = 1|D_{1:t-1}, d_t) = \text{Sigmoid}(\text{Linear}(h_{u_t}; h_{d_t}))$$

在这个公式中， **$;$** 确实表示向量的串联。 **$h_{d_t}$** 是内容 **$d_t$** 的特征向量。依据概率论，对于已观察到前 **$t - 1$** 篇内容集合 **$D_{1:t-1}$** 且对内容 **$t$** 实际未点击 ( **$y = 0$** )，不点击事件的概率是：

$$P(y = 0|D_{1:t-1}, d_t) = 1 - P(y = 1|D_{1:t-1}, d_t)$$

为了优化SINGLE模型，我们用**交叉熵损失** (CrossEntropy Loss) 作为目标，这是常用的监督学习误差衡量。计算公式为：

$$\mathcal{L} = -(y \log(\hat{p}(d_t|u_t)) + (1 - y) \log(1 - \hat{p}(d_t|u_t)))$$

通过最小化这个损失，模型能更好地学习区分实际点击和非点击行为，从而提高推荐的精度。

$$\mathcal{L} = \text{CrossEntropy}(y^*, P(y|D_{1:t-1}, d_t))$$

在这个上下文中， **$y^*$** 代表内容在第 **$t$** 次实际的点击状态，它可以根据用户是否对内容 **$t$** 进行了点击分为两类：1. 点击：如果用户选择了内容 **$t$** ，则 **$y^* = 1$** 。

通过优化模型的交叉熵损失，我们旨在最大化预测的点击概率与真实标签 $y^*$ 相匹配，从而提升推荐系统的准确性和召回率<sup>+</sup>。

### User Viewing Flow Modeling

我们使用 $h_{u_t}$ 表示，它是用户在第 $t$ 时刻的复合兴趣，由即时兴趣部分 $h_{u_t}^{ins}$ 和长期稳定兴趣部分 $h_{u_t}^{cons}$ 堆叠而成：

$$h_{u_t} = [h_{u_t}^{ins}; h_{u_t}^{cons}]$$

这种模型设计允许我们同时关注用户的短期动态行为和长期积淀的偏好，从而在推荐时提供更全面的用户理解，提高推荐的准确性和用户满意度。

$$h_{u_t} = h_{u_t}^{ins}; h_{u_t}^{cons}$$

你的理解非常准确。如果需要，我可以尝试根据上下文推测，但因为目前提供的信息没有具体的章节参考，我将基于一般论文结构进行解释。通常，这样的技术细节会出现在论文的方法或模型构建部分，可能是第3或4节，具体位置取决于论文的结构。关于用户即时观看流的模型，即 $h_{u_t}^{ins}$ ，可能会在User Viewing Flow Modeling (SINGLE)部分详细说明；而长期稳定兴趣的 $h_{u_t}^{cons}$ 可能在用户持久兴趣追踪或用户行为序列建模等相关章节讲解。如果有更具体的上下文，我可以给出更精确的位置。

### User Instant Viewing Flow Modeling

用户在阅读时的动态兴趣体现在瞬时偏好上，这涉及到对多个主题相关内容的关注。SINGLE模型通过聚焦于第 $t$ 时刻可能点击的内容 $d_t$ ，并从用户过去 $t-1$ 次浏览的内容集合 $D_{1:t-1}$ 中挖掘关联信息。这种方法将候选内容与用户过去的阅读历史相结合，通过注意力机制<sup>+</sup>(Eq.)来计算用户即时兴趣的表示：

$$u_t^{ins} = f_{att}(H_{1:t-1}, h_{d_t})$$

其中 $f_{att}$ 是一个注意力机制，它根据内容之间的语义相似性为每个历史内容分配权重，以形成一个融合的、反映即时兴趣的用户向量。这种方法确保模型能捕捉到用户在当下对内容的直接兴趣，为点击率预测提供依据。

$$h_{u_t}^{ins} = \sum_{i=1}^{t-1} \alpha_i \cdot h_{d_i}$$

$$\alpha_i = \text{softmax}(Q_k \cdot K_i^T)$$

其中： $-Q_k$ 是候选内容的特定子向量（如自注意力的query部分）与之相乘。 $-K_i$ 是对应内容 $i$ 的历史表示向量 $h_i$ 。 $-\text{softmax}$ 函数确保权重和为1，使结果是对所有内容的加权平均。这样计算出来的 $\alpha_i$ 用于调整每个历史内容在用户即时兴趣表示 $u_t^{ins}$ 中的比重，确保了模型能集中体现用户对当前内容的即时关注，从而优化推荐，满足用户即时需求。

$$\alpha_i = \text{softmax}_i(h_{d_t} \cdot W \cdot (h_{d_i})^T)$$

### User Constant Viewing Flow Modeling

在用户持续观看流建模中，我们不直接处理瞬时兴趣，而是聚焦于区分用户的普遍偏好与每次点击的独特动态。我们通过基于令牌级别的协同过滤<sup>+</sup>，模拟用户整体浏览行为，处理过去的点击序列 $D_{1:t-1}$ 。首先，我们将这些内容的文本表示连接起来，然后利用语言模型（LLMs）来识别共有的关键词<sup>+</sup>。同时，我们从序列中提取反映用户特质的信息，这有助于理解用户在不同行为中的长期稳定倾向，而非仅仅依赖最近一次的点击。这样做旨在创建一个更全面、个性化的用户模型，以提供更精准的推荐，而非仅基于瞬时兴趣。

$$u_t^{cons} = \text{LLM}(\text{instruct}_u, D_{1:t-1})$$

对于长期稳定兴趣的计算，我们使用函数 $f_{char}$ ，它结合了语言模型（LLMs）的能力。 $LLMs$ 不仅理解文本上下文，还能从用户过去行为的记录 $D_{1:t-1}$ 中提取深层次的持久特征。具体来说 $h_{u_t}^{cons}$ 通过 $f_{char}$ 接收这些信息，以刻画用户的长期习惯：

这个步骤增强了模型对用户稳定兴趣的把握，使得推荐更加贴合用户整体的价值观和兴趣，提高了推荐的质量。

$$h_{u_t}^{cons} = \text{BERT}(u_t^{cons}) \otimes h_{d_t}$$

在这个公式中，'⊗'表示点积运算<sup>+</sup>，用于将候选内容 $h_{d_t}$ 的语义与用户持久兴趣的表示' $h_{u_t}^{cons}$ '相结合。 $h_{d_t}$ 是BERT对内容的原始语义表示，而 $h_{u_t}^{cons}$ 是通过处理用户历史行为获得的个性化特征。通过点积，模型能够融合这两种信息：

$$h_{d_t}^{融合} = h_{d_t} \otimes h_{u_t}^{cons}$$

这样做旨在提升推荐的准确性，因为它同时考虑了用户对当前内容的即时兴趣以及长期的偏好。这种方法的参数与BERT编码器<sup>+</sup>共享，确保了模型在处理这两个方面时保持一致性和连贯性。

Experimental Methodology

我们详细阐述了实验的数据来源、衡量标准、对比基准以及操作步骤。数据集的选取和处理、评估指标的定义、常用的基线算法的介绍以及实验的具体操作流程，这些都是确保研究有效性的重要环节。

Datasets

- 1. ATA Dataset (Article Tracking Archive)：该数据集包含了用户点击历史和内容元数据，用于监测用户对内容的即时反应。
- 2. MIND Dataset (Multi-Modal Interest Network Dataset)：此数据集可能包含了用户的浏览行为、交互模式<sup>+</sup>以及可能的隐含兴趣信息，用于捕捉用户的长期兴趣趋势。

Table 1: Data Statistics of ATA and MIND.

Dataset	Data Info		Split	
	#User	#Article	Train	Test
ATA	44,758	146,219	9,196,714	52,583
MIND	2,000	6,444	24,140	2,800

具体的数据统计信息，如样本量、用户分布、内容类别分布等，会在实验前进行详细描述，以便准确评估模型<sup>+</sup>在不同环境下的性能。这些信息有助于我们比较不同模型的优劣，并为后续改进提供依据。

Evaluation Metrics

在实验中，我们依照先前研究的方法，通过考察AUC（曲线下面积）、MRR（平均逆内容检索排名）、nDCG@5和nDCG@10来评估推荐模型的有效性，这些都是评估召回率和排序质量的标准。同时，我们利用UVCTR（用户视图点击通过率）来评估SINGLE在ATA网站的实际应用效果，因为UVCTR直接反映了用户对推荐结果实际点击行为的反映，这对评估模型在真实环境中的实用性至关重要。所有这些指标都将帮助我们全面了解不同模型的性能表现。

$$UVCTR = \frac{\backslash \#users \text{ who clicked articles}}{\backslash \#users \text{ who visited the ATA homepage}}$$

Baselines

- 1. DCN：采用深度神经网络<sup>+</sup>，通过跨网络提取物品的多维特性，以捕捉高阶交互信息。



3. NPA：通过新闻标题编码生成查询，结合单词和内容级注意力机制构建个性化的注意力网络。
4. NAML：通过CNN编码新闻，利用多视图表示学习，通过注意力阅读来提升新闻内容的表示。
5. NRMS：不同于CNN，NRMS使用多头注意力机制来编码新闻标题，以更好地代表新闻内容。
6. FedRec：这是一种增强版的联邦学习推荐系统，保护用户隐私，通过用户模型和本地差分隐私<sup>+</sup>技术进行协作学习。

这些基线模型<sup>+</sup>提供了不同的推荐策略和技术，我们通过比较它们在AUC、MRR、nDCG@5和nDCG@10以及UVCTR指标下的表现，来评估它们在ATA网站上的实际效果。这有助于我们理解哪些模型能更准确地理解和满足用户的需求。

Implementation Details

这篇内容属于类别，它探讨了..通过对`article_body`深入研究，可以提炼出一个引人入胜的概要：..对于ATA数据集，由于隐私保护，我们采用了ChatGLM-6B模型来处理LLM任务。针对用户浏览新闻内容的总结，我们要求系统总结如下：用户在过去钟情于浏览..这些内容反映出他们对..的兴趣。请注意，对于ATA数据集，LLM摘要的生成指令是："请为标题为`article_title`，内容为`article_body`生成一篇200字的摘要。"

Evaluation Results

对于SINGLE模型效能，包括展示整体性能、深度剖析<sup>+</sup>各组件影响（通过ablative studies），并通过比较不同用户行为建模<sup>+</sup>策略的效力。此外，我们还通过在线A/B测试和实例研究，实际场景中测试模型<sup>+</sup>的实际应用效果，以确保其准确性和实用性。

Model	ATA				MIND			
	AUC	MRR	nDCG@5	nDCG@10	AUC	MRR	nDCG@5	nDCG@10
DCN [57]	67.69	40.81	50.48	61.01	63.43	40.40	47.56	57.67
DIN [74]	67.19	39.90	49.30	60.30	63.01	40.94	47.56	58.44
NPA [60]	67.05	39.55	49.04	59.96	61.22	38.69	43.27	55.72
NAML [59]	66.85	39.22	48.60	59.61	64.30	41.12	48.06	58.12
NRMS [62]	67.28	40.11	49.45	60.47	64.75	41.69	48.16	58.80
FedRec [42]	66.95	39.58	48.83	59.89	63.02	41.66	47.80	58.65
SINGLE	68.06	41.01	50.40	61.28	66.50	44.22	52.26	60.97

Ablation Studies

The Roles of Different User Viewing Flow Modeling Methods

我们通过分析点击内容主题的分布，揭示了即时浏览流反映用户即时兴趣，而持续浏览流体现长期关注趋势的特点。通过比较这两种流的表示向量相似度，我们看到它们互补且有助于揭示用户深层偏好。进一步研究，我们考察了SINGLE模型去除非流门（SINGLE w/o Flow Gate）和去除非用户简介推广（SINGLE w/o *Instruct<sub>u</sub>*）的效果，强调了这两个组件在提取用户持久偏好的关键作用，从而优化推荐策略。

Model	AUC	MRR	nDCG@5	nDCG@10
SINGLE	68.06	41.01	50.40	61.28
w/o Summarized Bodies	66.92	39.39	48.52	59.56
w/o Instant Flow	67.19	40.11	49.01	60.45
w/o Constant Flow	67.12	39.86	48.83	60.20
w/o Flow Gate	67.07	39.84	48.78	60.13
w/o <i>Instruct<sub>u</sub></i>	67.18	39.86	49.04	60.18

在图表中，我们选取了三位用户的点击内容主题分布，结果显示他们对JavaScript、Java和测试技术<sup>+</sup>有明显偏好，这证实了用户的专业兴趣。尽管如此，他们也会点击其他主题，显示多元化的兴趣点。这两种不同的阅读习惯对个性化推荐至关重要，因为它们分别反映了用户持久和即时的阅读兴趣。通过同时处理用户持续和即时浏览流，我们的模型能全面理解用户兴趣，推荐更符合个人喜好的内容<sup>+</sup>。用户持续兴趣的表示与点击内容高度相关，证明了我们的方法能从用户过去的阅读

Online A/B Test

我们通过在线A/B测试验证SINGLE模型的实际效果。系统设计包括在线服务和离线处理两部分，利用阿里云的高性能计算资源，SINGLE能高效地处理和预测内容。在ATA平台上，SINGLE与DCN进行对比，后者在ATA数据集上表现优异，是基准模型。2023年9月，我们连续7天在ATA平台上进行实验，以UVCTR作为评估标准，这是一个衡量推荐效果的公式。为确保公正比较，我们调整了平台的调度，确保每个模型分配了每天个性化首页流量的一半。实验数据显示，SINGLE的平均推荐效果比DCN高出2.4%，这在实际应用中证明了SINGLE在为ATA用户提供技术内容推荐时的优越性。




Figure 6: Recommendation Effectiveness of Different Methods in the Online A/B Test from Sep. 17, 2023 to Sep. 23, 2023.

原文《Modeling User Viewing Flow Using Large Language Models for Article Recommendation》

发布于 2024-04-12 10:49 · IP 属地北京

LLM 阿里巴巴集团 工业级推荐系统

赞同 5 添加评论 分享 喜欢 收藏 申请转载

理性发言，友善互动



还没有评论，发表第一个评论吧