

赞同 16

分享

领英2024：基于LLM技术赋能未来推荐系统



SmartMindAI

专注搜索、广告、推荐、大模型和人工智能最新技术，欢迎关注我

已关注

16 人赞同了该文章

Introduction

随着互联网内容激增，推荐系统（RS）对于在线平台至关重要。然而，过去RS主要依赖ID为基础的策略，用户和项目通过唯一的、连续ID嵌入来表示，这些ID通过历史交互学习相似性。代表性方法如PMF和双塔模型⁺中，ID嵌入可能随机初始化，或者依据用户特征和项目属性建立。

大型语言模型⁺（LLMs），如GPT、T5和LLaMA，因其在处理自然语言理解和模式识别上的出色表现，近年来在学术和工业领域受到广泛关注。这些模型通过预训练在海量语料库中学习，展现出强大的“涌现能力”。因此，利用LLMs开发推荐系统，能充分利用其编码的复杂知识、逻辑推理以及生成能力，精准解析用户/项目语义，从而提升推荐精度。

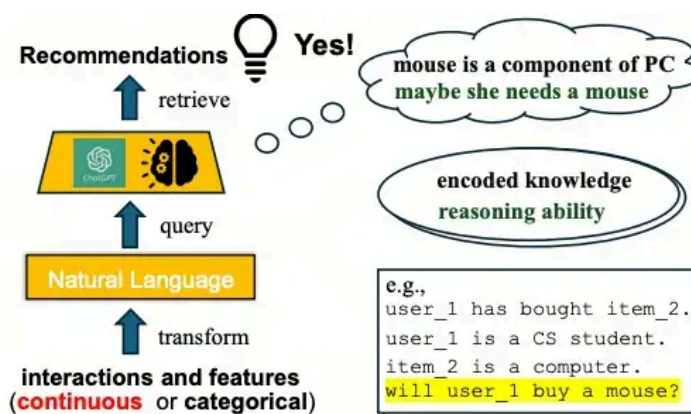


Figure 1: Prospectives of developing the next generation of recommender systems based on pretrained LLMs.

在现代在线服务中，鉴于用户和项目丰富多样的文本特性（如传记、描述、内容、评论和解释），这种方法的应用前景尤为广阔。一些初期研究已尝试将LLMs应用到推荐系统⁺，主要通过两个步骤操作：

(i) 替换传统的ID嵌入，以自然语言形式的‘提示’来表达用户和项目相关的互动信息（如项目历史、特征和候选项），而不是连续ID；

(ii) 利用LLM解析这些提示，从其文本输出中提取推荐所需信息，生成推荐建议。

尽管LLMs在学习用户/项目ID嵌入上有进步，实际应用中，有效利用它们进行推荐仍面临挑战。首先，非顺序信息处理（忽视交互顺序）与LLMs处理自然语言的顺序性矛盾。其次，内容建模中，模型可能误捕获不相关的特征。再者，LLMs的自回归特性降低了推荐效率，相对ID方法。最后，无论是通过ID还是描述索引，明确的提示对于避免误解至关重要，但这在处理大量候选和对响应时间敏感的场景中增加了复杂性。这些因素限制了LLM驱动推荐系统在实际场景中的广泛采用。

本文提出了一种结合ID与LLM的新推荐系统，通过优化预训练、提示设计和微调方法，它解决了LLM在推荐中的挑战，提升了推荐的精准度和运行效率。

- 我们研发了CLLM4Rec，这是一种独特的推荐系统，它将ID与LLM（语言模型）方法融合，创建了一个生成式推荐架构。通过将用户/项目ID嵌入到与LLM词汇空间相匹配的框架中，CLLM4Rec能更精确地理解用户内在兴趣和项目特性。这样，我们成功地解决了LLM在处理用户-项目关系时的难题，从而提升了推荐的精准度和实用性。
- 我们提出了一种创新策略，CLLM4Rec软硬结合预训练，通过正则化手段，实现了ID与LLM范式的融合。这种方法利用混合的描述交互和用户/项目特征的异构令牌，通过ID嵌入，既能优化协同过滤的协同信息，又能从内容特征中学习。在预训练阶段，这有助于深入理解和整合多种输入类型，显著增强了推荐的精准性和抗干扰能力。
- 我们采用了基于多项分布似然度的推荐引导微调策略。该策略利用软硬提示，以无误导的方式在遮盖的交互历史中对CLLM4Rec进行微调。通过预测预留项，模型能生成多个推荐，同时保证了推荐的精确性，减少了虚假推荐，提升了推荐系统的实用性和有效性。

Methodology

Problem Formulation

我们聚焦于基于隐式反馈的推荐系统，处理用户-物品互动的二进制评分数据。我们用 \mathbf{r}_i 表示用户对*i*个物品的交互情况，通过用户和物品的文本特征 $\mathbf{x}_i^u, \mathbf{x}_j^v$

以及联合特征 \mathbf{x}_{ij}^{uv} 来表示。文本序列被有序处理，每个位置用one-hot向量 $\mathbf{x}_{\{i,j,i\},k}^{\{u,v,uv\}}$ 表示。借助预训练LLM，我们视其为概率模型 p_{llm} ，通过多层自注意力学习上下文信息。LLM在大规模语料库上预训练，通过微调在特定示例上生成后续令牌 \mathbf{x}_{k+1} ，利用其对上下文的逻辑推理，利用其预训练知识进行推荐。我们设计了一个生成式推荐系统，结合LLMs和推荐任务，通过整合用户/项目ID及对应的令牌嵌入，以精确捕捉用户和项目的语义，如兴趣表达。这种方法利用预训练LLM的深度学习能力和推理能力，强化了对用户需求的理解，从而实现精准且高效的推荐。

Extension of User/Item Tokens

Token Embeddings

对于LLMs理解和处理新增用户/项目令牌，我们首先将其转化为密集的嵌入向量，记作 $\mathbf{z}_k^t \in \mathbb{R}^K$

对于用户/项目特有的标记，我们采用两种与原词汇空间一致的方式生成嵌入，以精确反映用户/项目交互及内容含义。具体操作是，我们从相同的K维潜在空间中随机抽取用户/项目协作的嵌入，这样设计旨在保持原始语义的连贯性。

$$\mathbf{z}_i^{l,u}, \mathbf{z}_j^{l,v} \sim \mathcal{N}(\mathbf{0}, \lambda_l^{-1} \cdot \mathbf{I}_K)$$

通过随机从相同K维潜在空间中采样用户/项目协作的嵌入，我们定义用户/项目内容令牌的嵌入为 $\mathbf{z}_{u,i}^{c,t}$ ，它遵循这样的概率分布：

$$\mathbf{z}_{u,i}^{c,t} \sim P(\mathbf{z}^{c,t} | \mathbf{z}_i^{l,u}, \mathbf{z}_j^{l,v})$$

这个过程确保了用户和项目内容的个性化信息在推荐中得以准确嵌入，同时与协作信息保持一致，从而提升推荐系统的精确性和效力。

$$\mathbf{z}_i^{c,u} \sim \mathcal{N}(\mathbf{z}_i^{l,u}, \lambda_c^{-1} \cdot \mathbf{I}_K), \mathbf{z}_j^{c,v} \sim \mathcal{N}(\mathbf{z}_j^{l,v}, \lambda_c^{-1} \cdot \mathbf{I}_K)$$

$\mathbf{Z}^{l,\{u,v\}}$ 承载用户和物品的联合信息，而 $\mathbf{Z}^{c,\{u,v\}}$ 则是从条件先验中提取的用户和项目内容特征。这些嵌入组合在一起，构成推荐任务所需的全面语义表达，目的是在推荐时有效地融合用户独特内容和协作信息，以提高推荐的精确性和效果。

CLLM4Rec Base Model

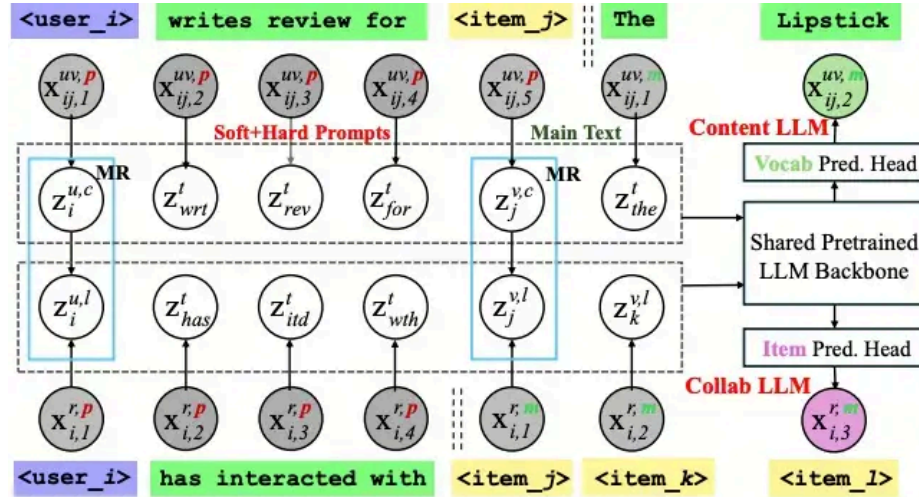


Figure 2: The overview of the proposed CLLM4Rec in the mutually-regularized pretraining stage. Mutual regularization for item_k is omitted for simplicity.

构建的CLLM4Rec模型 (\mathbf{M}) 基于用户/项目标记与嵌入，它通过集成这些特有的标识和丰富语义来增强对LLMs预训练知识的利用。该模型设计的目的是深化理解和应用LLMs的能力，使其在推荐过程中能精确地处理用户和项目的独特内容，以及协作信息，从而显著提升推荐的精确性和运行效率。

$$\mathbf{h}_{\{l,c\},1:k}^{(L)} = \hat{\mathbf{U}}_{\{l,c\}}(\mathbf{x}_{1:k})$$

在CLLM4Rec模型中，使用 L 层自注意力结构，对令牌序列 $\mathbf{x}_{1:k}$ 进行处理，将其映射到维度为 $k \times K_h$ 的隐藏空间

$$\mathbb{R}^{k \times K_h}$$

每个 \mathbf{x}_k 是 $(N + I + J)$ 维的one-hot向量，分别代表用户、项目和词汇的令牌。通过索引 $\hat{\mathbf{U}}_{\{l,c\}}$ ，确定使用哪个嵌入矩阵： l 对应应用户/项目部分的 $\mathbf{Z}^{l,\{u,v\}}$ ， c 对应内容部分的 $\mathbf{Z}^{c,\{u,v\}}$ 。基础的CLLM4Rec模型仅训练用户/项目嵌入，而词汇嵌入 \mathbf{Z}^t 和LLM的其余部分保持固定，以保留其预先学习的特征。

Mutually-Regularized Pretraining

在CLLM4Rec模型扩展中，我们引入了相互正则化预训练策略。该策略旨在通过利用用户-项目交互和用户-项目文本数据，利用语言建模来优化用户/项目特定的令牌嵌入。这通过在基于交互和内容的语料库中学习实现，以充分利用预训练LLM的深度理解和推理功能。这一过程如图所示。

Recommendation-Specific Corpora

(a) *Historical Interactions* \mathbf{r}_i :

$\langle \text{user_i} \rangle$ has interacted with $\langle \text{item_j} \rangle \langle \text{item_k} \rangle \dots$

(b) *User/Item Textual Features* $\mathbf{x}_i^u, \mathbf{x}_j^v, \mathbf{x}_{ij}^{uv}$:

The biography of $\langle \text{user_i} \rangle$ is: Main biography.

The content of $\langle \text{item_j} \rangle$ is: Main contents.

$\langle \text{user_i} \rangle$ writes the review for $\langle \text{item_j} \rangle$: Main reviews.

一般来说，我们可以将用户-项目交互数据 \mathbf{r}_i 和用户/项目内容特征 $\mathbf{x}_i^u, \mathbf{x}_j^v, \mathbf{x}_{ij}^{uv}$ 转化为用户/项目/词汇的序列文档，步骤如下：

1. 用户内容表示：

$$\mathbf{d}_i^u = \{\mathbf{z}_i^{l,u}, \mathbf{z}_{u,1}^{c,t}, \dots, \mathbf{z}_{u,M_u}^{c,t}\} \quad (\text{用户内容令牌序列})$$

1. 项目内容表示：

$$\mathbf{d}_j^v = \{\mathbf{z}_j^{l,v}, \mathbf{z}_{v,1}^{c,t}, \dots, \mathbf{z}_{v,M_v}^{c,t}\} \quad (\text{项目内容令牌序列})$$

1. 用户-项目交互表示：

$$\mathbf{d}_{ij} = \{\mathbf{r}_i, \mathbf{x}_{ij}^{uv}\} \quad (\text{交互与内容联合序列})$$

其中 M_u 和 M_v 分别表示用户和项目各自的令牌数量 $\mathbf{z}_{u,m}^{c,t}$ 和 $\mathbf{z}_{v,n}^{c,t}$ 是对应位置的用户和项目内容令牌的嵌入。通过这种方式，我们将多模态信息转化为适合LLM处理的序列格式，以便在预训练过程中进行联合学习，最大化地利用LLM的上下文理解能力和推理能力。

Raw Corpora Transformed from Recommendation Data

由于实际语料库中存在异构的词汇、用户和项目令牌，直接在原始数据上进行语言建模并不现实，尤其是因为关键的有意义词汇可能被大量随机初始化的非核心内容淹没。因此，我们需要将多模态信息转换为LLM能理解的格式。这通常涉及对用户内容、项目内容以及用户与项目交互的结构化表示，如前文所述的步骤。例如，对于亚马逊美容数据集，我们不会忽视用户的独特信息，而是构建用户内容序列 \mathbf{d}_i^u 和项目内容序列 \mathbf{d}_j^v ，将它们转换为LLM熟悉的格式。这样做的目的是在保持对核心信息关注的同时，利用LLM强大的语义理解和推理能力，克服文档复杂性和大量随机词汇的挑战。

Soft+Hard Prompting

(a) *Historical Interactions* \mathbf{r}_i :

$\langle \text{user_i} \rangle$ has interacted with $\langle \text{item_j} \rangle \langle \text{item_k} \rangle \dots$

soft+hard prompt $\mathbf{x}_i^{r,p}$

item token seq. $\mathbf{x}_i^{r,m}$

我们面临的是异质的用户/项目标记与同质的项目内容之间的混合，其中软提示（用户/项目特性）和硬提示（词汇）提供文档主题的上下文，而主文本部分由固定词汇构成。为了优化语言建模，我们区分这两部分：首先在硬提示部分进行，然后对同质项目令牌序列进行。通过将用户历史交互的文档 \mathbf{x}_i^r 拆分为软硬两部分 $\mathbf{x}_i^{r,p}$ 和 $\mathbf{x}_i^{r,m}$ ，我们引导模型专注于协作和内容信息，避免了非核心词汇干扰，提升了模型在推荐任务中的效果。这种方法有效应对了复杂语料库中的词汇多样性问题。

(a) *Historical Interactions* \mathbf{x}_i :

我们提出协同LLM（Cooperative Language Modeling, C-LLM），它是基于基础的CLLM4Rec模型 $\hat{\mathbf{U}}\mathbf{m}_i$ ，增加了一个预测头 \mathbf{f}_i 。这个头将 $\hat{\mathbf{U}}\mathbf{m}_i$ 最后一层的隐状态向量 $\mathbf{h}_{i,-1}$ 映射到项目类别空间，通过softmax操作计算每个项目概率。具体地

其中 $\mathbf{Z}^{l,v}$ 是各层的协同令牌嵌入。C-LLM生成过程是：预测下一个项目 \mathbf{y}_{t+1} 的概率由用户交互的软硬提示 $(\mathbf{x}_i^r, \mathbf{x}_i^m)$ 、所有层的协同令牌信息 \mathbf{Z}^l 以及上一时刻的隐状态 $\mathbf{h}_{l,-1}$ 共同决定，即

$$\mathbf{y}_{t+1} \sim p(\mathbf{y}_{t+1} | \mathbf{x}_i^r, \mathbf{x}_i^m, \mathbf{Z}^l, \mathbf{h}_{l,-1})$$

这样的协同建模策略能有效处理语料库中的词汇多样性问题，提升推荐系统的效能。

$$\mathbf{x}_{i,k+1}^{r,m} \sim p_{\hat{llm}_i}^{f_i}(\mathbf{x}_{i,k+1}^{r,m} | \mathbf{x}_{i,1:k}^{r,m}, \mathbf{x}_i^{r,p})$$

提示向量 $\mathbf{x}^{r,p}$ 用于引导LLM生成下一个项目，而生成 $\mathbf{x}_{i,k+1}^{r,m}$ 时，LLM会考虑之前项目的信息。协同LLM通过优化似然性，促使用户 i 的用户令牌嵌入 $\mathbf{z}_i^{l,u}$ 与项目相关令牌如 $\mathbf{z}_j^{l,v}$ 、 $\mathbf{z}_k^{l,v}$ 等相互靠近，以捕捉用户与项目间的协同语义。

文档内容同样如此，根据用户 i 与项目 j 的交互，将其划分为软性和硬性提示部分 $\mathbf{x}_{ij}^{uv,p}$ 以及同质词汇的主体文本部分 $\mathbf{x}_{ij}^{uv,m}$ ，以便LLM能全面理解用户和项目的内容。

(b) User/Item Textual Features $\mathbf{x}_{ij}^{uv}:$

我们提出**内容LLM**，通过在基础的CLLM4Rec模型 \hat{llm}_c 上附加词汇预测头 f_c ，该头将最终隐藏状态 $\mathbf{h}_{c,-1}$ 映射到词汇**概率空间**⁺。 \hat{llm}_c 利用预训练LLM，但使用用户/项目特定的嵌入 $\mathbf{Z}^{c,\{u,v\}}$ 进行解码。 f_c 的权重与词汇嵌入 \mathbf{Z}^t 关联，通过 $\mathbf{Z}^t \cdot \mathbf{h}_{c,-1}$

计算softmax输出。内容LLM生成过程为：

$$p_{\text{content}}(n|c) = f_c(\mathbf{h}_{c,-1})$$

这里 $p_{\text{content}}(n|c)$ 表示基于内容LLM以 c 为中心生成下一个符号的条件概率。

$$\mathbf{x}_{ij,k+1}^{uv,m} \sim p_{\hat{llm}_c}^{f_c}(\mathbf{x}_{ij,k+1}^{uv,m} | \mathbf{x}_{ij,1:k}^{uv,m}, \mathbf{x}_{ij}^{uv,p})$$

Mutually-Regularization

为了解决预训练LLMs可能捕获不相关内容及协同LLM过拟合问题，我们提出一种相互正则化的预训练策略。这种策略通过协同LLM指导内容LLM提取推荐相关特征，同时内容LLM也引入侧面信息以辅助协同过滤。对于用户 i ，我们考虑其与项目交互的堆叠嵌入 $\mathbf{Z}_i^{c,v}$ 和 $\mathbf{Z}_i^{l,v}$ ，其中 $\mathbf{Z}_i^{l,v}$ 包含所有项目，包括已交互和未交互的。对应的CLLM4Rec生成过程是联合分布：

$$p_{\text{CLLM4Rec}}(\text{user}, \text{content} | i) = p(\text{content} | \text{user}, \mathbf{Z}_i^{c,v}, \mathbf{Z}_i^{l,v}) \times p(\text{user} | i)$$

这里 $p(\text{content} | \text{user}, \mathbf{Z}_i^{c,v}, \mathbf{Z}_i^{l,v})$ 由内容LLM生成，利用协同LLM理解推荐相关性；而 $p(\text{user} | i)$ 则来自协同LLM对用户行为的理解。通过这种方式，两者相互校正，提高模型泛化能力和推荐准确性。

$$\begin{aligned} p(\mathbf{x}_i^{r,m}, \mathbf{x}_{ij}^{uv,m}, \mathbf{z}_i^{l,u}, \mathbf{Z}_i^{l,v}, \mathbf{z}_i^{c,u}, \mathbf{Z}_i^{c,v} | \mathbf{x}_i^{r,p}, \mathbf{x}_{ij}^{uv,p}) = \\ \underbrace{\prod_k p_{\hat{llm}_i}^{f_i}(\mathbf{x}_{i,k}^{r,m} | \mathbf{x}_{i,1:k-1}^{r,m}, \mathbf{x}_i^{r,p})}_{\text{\color{blue} \texttt{LM for collab. LLM}}} \cdot \underbrace{\prod_k p_{\hat{llm}_c}^{f_c}(\mathbf{x}_{ij,k}^{uv,m} | \mathbf{x}_{ij,1:k-1}^{uv,m}, \mathbf{x}_{ij}^{uv,p})}_{\text{\color{RGB}{0,128,0} \texttt{LM for content LLM}}} \cdot \\ \underbrace{p(\mathbf{z}_i^{c,u} | \mathbf{z}_i^{l,u}) \cdot \prod_k p(\mathbf{z}_{ik}^{c,v} | \mathbf{z}_{ik}^{l,v})}_{\text{\color{purple} \texttt{mutual regularization}}} \cdot \underbrace{p(\mathbf{z}_i^{l,u}) \cdot \prod_k p(\mathbf{z}_{ik}^{l,v})}_{\text{\color{purple} \texttt{prior}}} \end{aligned}$$

观察公式，我们发现联合分布由三个部分构成：

1. 协同与内容LLM：它们分别通过公式学习用户/项目嵌入；
2. 相互正则化：用户和项目嵌入间的条件高斯分布，通过MSE正则化约束差异；
3. 忽略先验：在正则化中 $\mathbf{z}_i^{l,u}$ 和 $\mathbf{z}_{ik}^{l,v}$ 的先验项($\lambda_l = 0$)被忽略，以避免无谓信息干扰。

式定义。通过交替优化，针对协同LLM（L步）和内容LLM（C步）：

- 对于协同LLM，目标为：

$$\min_{\theta_L} \log p(\mathbf{z}_i^{c,u}, \mathbf{z}_i^{l,u} | \mathcal{D}) \approx -\frac{1}{2} \sum_k \|\mathbf{z}_i^{c,u} - f_c(\mathbf{z}_i^{l,u}, \mathbf{x}_{ik}^{uv})\|_2^2 + \text{const.}$$

其中 \mathcal{D} 是训练数据 f_c 依赖于输入和嵌入的预测。

- 对于内容LLM，目标为：

$$\min_{\theta_C} \log p(\mathbf{z}_{ik}^{c,v}, \mathbf{z}_{ik}^{l,v} | \mathcal{D}) \approx -\frac{1}{2} \sum_j \|\mathbf{z}_{ik}^{c,v} - f_c(\mathbf{z}_{ik}^{l,v}, \mathbf{x}_{ij}^{uv})\|_2^2 + \text{const.}$$

交替更新这些参数使得模型能最大化似然，从而达到协同和内容LLM的协作，同时减少无关特征的干扰和过拟合风险。我们使用MAP估计优化时，目标变为估计用户和项目嵌入 \mathbf{z} ，利用内容嵌入 $\hat{\mathbf{z}}$ 作为指导，以 \mathbf{x}_i^r 和 \mathbf{x}_{ij}^{uv} 为输入，通过已有的内容LLM（C步）嵌入 $\hat{\mathbf{z}}_i^{c,v}$

协同LLM（L步）的目标函数为：

$$\min_{\theta} \log p(\mathbf{x}_i^r, \mathbf{x}_{ij}^{uv} | \hat{\mathbf{z}}_i^{c,u}, \hat{\mathbf{z}}_i^{c,v}, \mathcal{D}) \approx -\frac{1}{2} \sum_k \|\mathbf{z}_i^{l,u} - f_l(\mathbf{z}_i^{l,u}, \mathbf{x}_{ik}^{uv}; \theta)\|_2^2 + \text{const.}$$

这里，我们利用内容LLM的嵌入来引导协同学习，减少对无关特征的过度拟合，同时两者协同优化以提升用户体验和推荐准确性。

$$\begin{aligned} \mathcal{L}_{\text{1_step}}^{\text{MAP}}(\mathbf{z}_i^{l,u}, \mathbf{z}_i^{l,v}; \theta) &= \sum_k \underbrace{-\ln p_{llm_l}^f(\mathbf{x}_{i,k}^{r,m} | \mathbf{x}_{i,1:k-1}^{r,m}, \mathbf{x}_i^{r,p})}_{\text{\color{blue} \texttt{LM loss for collab. LLM}}} \\ &+ \underbrace{\frac{\lambda_c}{2} \|\mathbf{z}_i^{l,u} - \hat{\mathbf{z}}_i^{c,u}\|_2^2 + \sum_k \frac{\lambda_c}{2} \cdot \|\mathbf{z}_{ik}^{l,v} - \hat{\mathbf{z}}_{ik}^{c,v}\|_2^2}_{\text{\color{purple} \texttt{MR loss with content LLM}}} + \underbrace{\frac{\lambda_l}{2} \|\mathbf{z}_i^{l,u}\|_2^2 + \frac{\lambda_l}{2} \|\mathbf{z}_j^{l,v}\|_2^2}_{\text{\color{purple} \texttt{Prior loss}}} + \mathcal{C}_l, \end{aligned}$$

在这个模型中，我们不直接优化 \mathcal{C}_l ，它作为一个常数不参与计算。语言模型损失通过比较用户 i 的令牌嵌入 $\mathbf{z}_i^{l,u}$ 与互动项的嵌入 \mathbf{x}_{ij}^{uv} 来衡量协同效应，这反映了协同关系的学习。MR损失（Mean Rank Loss）通过引入额外的侧面信息，增强了协同过滤的效果，从而更高效地促进协同学习。在C步，当L步迭代结束后，我们暂时固定用户/项目协同的嵌入 $\mathbf{z}_i^{l,u}$ 和 $\mathbf{z}_j^{l,v}$ 为估计值 $\hat{\mathbf{z}}_i^{l,u}$ 和 $\hat{\mathbf{z}}_j^{l,v}$ 基于这个，内容LLM的复合目标函数变为：

$$\min_{\theta_C} \log p(\mathbf{z}_{ik}^{c,v}, \mathbf{z}_i^{c,u} | \mathcal{D}, \hat{\mathbf{z}}_i^{l,u}, \hat{\mathbf{z}}_j^{l,v}) \approx -\frac{1}{2} \sum_j \|\mathbf{z}_{ik}^{c,v} - f_c(\hat{\mathbf{z}}_{ik}^{l,v}, \mathbf{x}_{ij}^{uv})\|_2^2 + \text{const.}$$

在这个阶段，内容LLM利用已确定的协同信息来改进对项目内容的解析，以此减少对无关特征的依赖，同时降低过拟合风险。

$$\begin{aligned} \mathcal{L}_{\text{c_step}}^{\text{MAP}}(\mathbf{z}_i^{c,u}, \mathbf{z}_j^{c,v}; \theta) &= \sum_k \underbrace{-\ln p_{llm_c}^f(\mathbf{x}_{ij,k}^{uv,m} | \mathbf{x}_{ij,1:k-1}^{uv,m}, \mathbf{x}_{ij}^{uv,p})}_{\text{\texttt{LM loss for content LLM}}} \\ &+ \underbrace{\frac{\lambda_c}{2} \|\mathbf{z}_i^{c,u} - \hat{\mathbf{z}}_i^{l,u}\|_2^2 + \frac{\lambda_c}{2} \cdot \|\mathbf{z}_j^{c,v} - \hat{\mathbf{z}}_j^{l,v}\|_2^2}_{\text{\color{purple} \texttt{MR loss with collab. LLM}}} + \mathcal{C}_c, \end{aligned}$$

在这个协同学习的框架中，

MR loss 被用来驱动内容LLM专注于捕获与推荐紧密相关的用户/项目文本特征。目标函数更新如下：

1. L步：

$$\min_{\theta} \text{MR Loss} + \lambda_c \cdot \text{内容LLM目标}$$

其中内容LLM目标是基于固定协同嵌入的复合函数，用上述的

1. C步：

$$\min_{\theta_c} \text{MR Loss} + \lambda_c \cdot \text{内容LLM更新后的目标}$$


内容LLM在此阶段根据共享的协同信息更新其目标，但保持与L步相同的形式，即 $\log p(\text{内容})$ 加上正则项。 λ_c 参数控制了两个LLM之间的正则化程度，我们在实验中会详细探讨如何合理设置以达到最优效果。

Stochastic Item Reordering

当从历史交互向量 \mathbf{r}_i 生成令牌序列 $\mathbf{x}_i^{r,m}$ 时，项目顺序问题可能导致推荐效能下降。由于用户的长期兴趣通常稳定，顺序并不关键，但直接处理可能丢失顺序信息。为此，我们提出一个随机项目重排策略。在优化协同LLM（如等式所展示）时，我们会随机打乱这些令牌顺序。这样，我们既避免了顺序对固定提示（软+硬prompt）的影响，又能确保在忽略顺序的同时，有效地利用了LLM来捕捉项目相关性。

Recommendation-Oriented Finetuning

Masked Prompting with Multinomial Prediction Head



为改进CLLM4Rec并使其更适合推荐任务，我们设计了一种策略来生成推荐导向的提示。首先，对于用户 i ，我们以概率 p_m 随机遮盖其已交互过的项目 \mathbf{r}_i ，剩余项目成为 \mathbf{r}_i^{masked} 。然后，利用这些被遮盖的项目，我们生成一个针对推荐的提示向量 $\mathbf{x}_i^{rec,p}$ 。对于未参与训练的holdout项目，我们用多-hot编码的向量 \mathbf{r}_i^{hold} 作为目标。构建这个推荐导向提示的向量 $\mathbf{x}_i^{rec,p}$ 的具体方法是基于 \mathbf{r}_i^{masked} 进行设计的。

$$\text{RecLLM} : \mathbf{r}_i^{hold} \sim p(\mathbf{r}_i^{hold} | \mathbf{r}_i^{masked}, \hat{\mathbf{Z}}^{l,v}, \hat{\mathbf{m}}_l)$$

这里， \sim 代表通过RecLLM模型根据遮罩项和预训练LLM环境预测holdout项的潜在分布。

$$\mathbf{r}_i^{hold} \sim \text{multi}(f_{rec}(\mathbf{h}_{i,i-1}^{rec}), N_i^{hold}), \text{ where } \mathbf{h}_{i,i}^{rec} = \hat{\mathbf{m}}_l(\mathbf{x}_i^{rec,p})$$

Predictions with CLLM4Rec

在CLLM4Rec完成后，为用户 i 生成建议，我们利用用户的历史交互数据 \mathbf{r}_i 生成推荐导向的提示向量 $\mathbf{x}_i^{rec,p}$

这遵循之前章节的描述（不包括遮盖部分）。接下来，这个提示输入RecLLM模型进行一次前向传播，得到每个项目的多项分布概率 $\hat{\mathbf{r}}_i$ ，计算公式是

$$\hat{\mathbf{r}}_i = \text{multi}(f_{rec}(\hat{\mathbf{h}}_{i,-1}^{rec}))$$

其中 $\hat{\mathbf{h}}_i^{rec}$ 是通过 $\hat{\mathbf{m}}_l$ 处理后的 $\mathbf{x}_i^{rec,p}$

最后，我们选取得分最高的 M 个未互动项作为推荐。

Experimental Setup

Datasets

10%用于验证，10%作为测试，且确保验证集和测试集中至少包含用户一次已有的交互。用户评论 x_{ij}^{uv} 被转化为文本特征，而LinkedIn的职位推荐数据集则通过用户的工作广告（隐性反馈）和用户自我描述 x_i^u 、工作描述 x_j^v 作为输入。

Qualitative Analysis.

对于非4Rec类型的基于LLM推荐系统，如伪ID和描述型方法，它们用多令牌表示用户和项目，并将推荐理解为生成下一项的作业。但由于生成的令牌可能与推荐目标不符，需要明确提示来避免误导（如P5需从100个候选中找一个正例，而TALLRec基于描述做二元判断）。CLLM4Rec能同时生成多项推荐，不适用于直接比较。因此，这些方法的评估主要基于定性讨论，而非量化分析。

Results on the Public Datasets

我们首先通过在四份公开数据集上的实证研究，对RQs1, 2, 3给出了初步解答。结果显示，基于ID的传统方法（如Multi-VAE）在协同过滤领域仍是最强基准。尽管LLM4Rec的CF部分（LLM-CF）在AM-Sports和Toys集上未能超越Multi-VAE，尽管预训练LLM在硬提示下有所表现，但面对大量文本数据时，LLM4Rec显著优于MD-CVAE，这是由于LLM预训练带来的深层理解优势，而MD-CVAE依赖词袋特征，与LLM不符。LLM-Scratch模型表现不佳，进一步证实了预训练知识的价值。

Table 1: Comparison between CLLM4Rec and various baselines with GPT-backbone on three Amazon Review datasets.

AM-Beauty	Recall@20	Recall@40	NDCG@100
Multi-VAE	0.1295	0.1720	0.0835
MD-CVAE	0.1472	0.2058	0.0976
BERT4Rec	0.1126	0.1677	0.0781
S ³ Rec	0.1354	0.1789	0.0867
LLM-Scratch	0.0840	0.1265	0.0583
LLM-CF	0.1319	0.1841	0.0855
LLM-FtAll	0.1335	0.1988	0.0836
LLM-FixOrd	0.1524	0.2219	0.1072
LLM-PreRec	0.1547	0.2196	0.1051
CLLM4Rec	0.1656	0.2323	0.1118

值得注意的是，整体微调模型LLM-FtAll（包括预训练LLM）虽尝试适应，但不如LLM4Rec，可能因预训练权重已优化，对特定任务适应不足。LLM-PreRec在使用LLM生成推荐时表现出强劲性能，这表明混合硬软提示策略在异构令牌的推荐任务中有效。然而，LLM4Rec仍优于LLM-PreRec，证实了对预训练LLM进行针对推荐任务的定向微调的有效性。

Results on the LinkedIn Dataset

实验中，我们将CLLM4Rec与LinkedIn的两塔模型（TT模型）和基于LLM的推荐系统M6-Retrieval进行了对比。TT模型是双层MLP，利用GNN提取的用户/项目嵌入及BERT特征。尽管CLLM4Rec在性能上优于基础的浅层TT模型，但推荐任务导向的微调虽带来推理速度改善，但由于计算成本高，不适合直接上线。为此，我们设计了CLLM4Rec-Emb基线，将CLLM4Rec的嵌入输入到TT模型，这在离线实验中证实了其性能提升，证明了CLLM4Rec在对延迟要求高的场景中有潜在应用价值。

Yelp	Recall@20	Recall@40	NDCG@100
Multi-VAE	0.0526	0.0842	0.0424
MD-CVAE	0.0664	0.1058	0.0497
BERT4Rec	0.0418	0.0724	0.0361
S ³ Rec	0.0563	0.0893	0.0485
LLM-Scratch	0.0199	0.0325	0.0159
LLM-CF	0.0541	0.0860	0.0412
LLM-FtAll	0.0653	0.0989	0.0520
LLM-FixOrd	0.0694	0.1053	0.0524
LLM-PreRec	0.0639	0.1021	0.0498
CLLM4Rec	0.0735	0.1149	0.0536

LinkedIn	Recall@10	Recall@20	NDCG@10
Two-Tower	0.1186	0.2041	0.0979
M6-Retrieval	0.1279	0.2118	0.1020
CLLM4Rec-Emb	0.1302	0.2165	0.1034
CLLM4Rec	0.1427	0.2398	0.1199

Parameter Sensitivity Analysis

为了解答RQ2和RQ3，我们通过调节 λ_c 探究其正则化强度，通过Eqs. ()和()中的 λ_c 来实现。观察发现，当 λ_c 较小，正则化作用较弱，内容LLM难以为推荐模型提供充分的用户/项目内容信息，导致推荐性能下降到类似LLM-CF的水平。相反，若 λ_c 过大，MR (Mean Rank) 损失过重，可能导致CLLM4Rec的语义学习受阻。在所有数据集上，CLLM4Rec的最佳性能出现在 $\lambda_c \approx 1$ 处，这为将基于GPT的模型应用到新数据集提供了合适的选择。




Figure 4: Sensitivity analysis w.r.t. λ_c , which controls the strength of mutual-regularization for CLLM4Rec.

原文《Collaborative Large Language Model for Recommender Systems》

发布于 2024-04-16 10:26 · IP 属地北京

推荐系统 LLM (大型语言模型) 工业级推荐系统