

# CIKM2024 | QueryRec: 利用搜索域提升推荐域CTR预估能力

ML\_RSer 机器学习与推荐算法 2024年12月31日 08:20 中国香港

嘿，记得给“机器学习与推荐算法”添加星标

作者：Recommender

链接：<https://zhuanlan.zhihu.com/p/11361195104>

**TLDR:** 为了解决推荐系统中用户在搜索和推荐领域间偏好转移的问题，本文提出了QueryRec框架。该框架利用搜索域中的用户查询序列来预测推荐域中用户下次点击的物品，并通过对比学习和扩散模型来探索查询与物品间的关系，以解决数据稀疏问题。实验表明，QueryRec在推荐域中的表现超过了现有模型，有效提升了点击率预估的准确性。

## Enhancing CTR prediction in Recommendation Domain with Search Query Representation

Yuening Wang\*  
Huawei Noah's Ark Lab  
Markham, Canada  
yuening.wang@huawei.com

Man Chen\*  
Huawei Noah's Ark Lab  
Montreal, Canada  
man.chen1@huawei.com

Yaochen Hu  
Huawei Noah's Ark Lab  
Montreal, Canada  
yaochen.hu@huawei.com

Wei Guo  
Huawei Noah's Ark Lab  
Singapore, Singapore  
guowei67@huawei.com

Yingxue Zhang  
Huawei Noah's Ark Lab  
Markham, Canada  
yingxue.zhang@huawei.com

Huifeng Guo  
Huawei Noah's Ark Lab  
Shenzhen, China  
huifeng.guo@huawei.com

Yong Liu  
Huawei Noah's Ark Lab  
Singapore, Singapore  
liu.yong6@huawei.com

Mark Coates  
McGill University  
Montreal, Canada  
mark.coates@mcgill.ca

论文：<https://arxiv.org/abs/2410.21487>

## 1 问题背景

许多在线平台同时提供推荐和搜索服务，推荐系统在用户浏览时主动推荐内容，搜索服务则允许用户主动查找特定商品。因此，如何有效利用推荐和搜索领域的的数据成为一个重要问题。该paper聚焦于搜索和推荐领域联动下的CTR预测问题。

现有研究已针对推荐和搜索领域的联合学习进行了多种探索，一些研究通过引入搜索数据来更好地理解推荐领域中的用户行为，另一些则将推荐行为视为具有零查询的搜索行为特例，从而实现两者的整合。

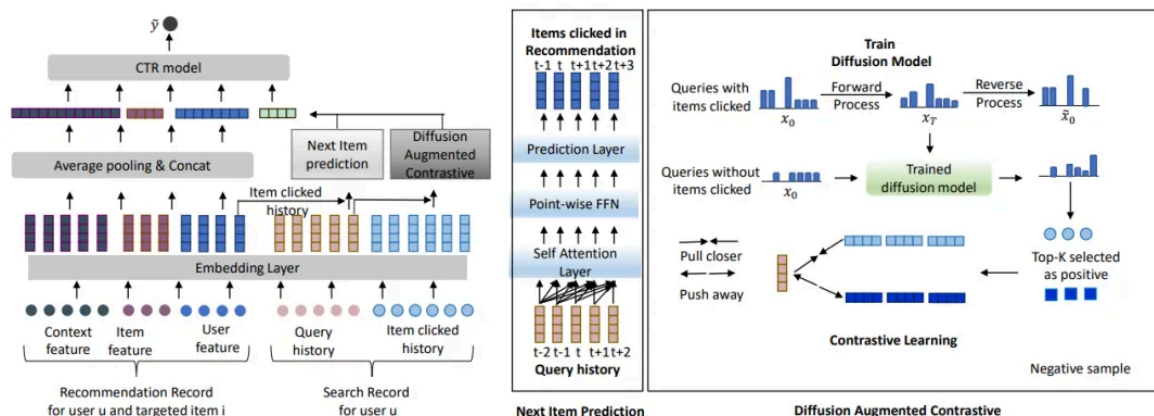
然而，现有方法仍存在一些问题：

- 跨域兴趣转移：** 现有方法通常隐含假设用户在各个领域中的兴趣具有统一性，而忽略了用户在浏览和搜索之间的意图变化，未考虑到这两个领域之间的兴趣转移。因此，有效捕捉跨域之间用户偏好的潜在变化对于准确预测用户兴趣至关重要。

2. **query与item对齐问题**: 搜索领域中的query通常与对应item紧密相关, 或可以提供item描述信息。深入挖掘query与item关系可增强query表征, 从而提升推荐系统效果。然而, 许多query没有点击记录, 现有方法简单地忽略了这些无点击query, 无法充分捕捉查询与物品之间的关系, 如何处理这些无点击查询仍是一个挑战。

## 方法

本文所提出框架如下图所示。



所提出的QueryRec框架

具体的, 来自搜索领域的查询表示通过下一个项目预测和扩散增强的对比学习模块进行完整学习。这种精炼的表示与推荐领域的其他特征结合, 并用于CTR预测模型。对于下一个项目预测, 直到时间点 $t$ 的查询序列通过自注意力层和逐点前馈网络(FFN)进行编码, 然后预测用户在推荐领域中时间点 $t + 1$ 将点击的项目。

在扩散增强的对比学习中, 扩散模型首先使用搜索某些查询后点击的项目记录进行训练。 $x_0$ 是用户在特定查询后会点击的项目的概率。考虑到用户可能仍然对未曝光的项目感兴趣, 因此也给未曝光的项目分配了 $[-1, 1]$ 中的一个值。经过扩散模型的逆过程后, 我们得到 $\tilde{x}_0$ , 这是搜索领域中原始的项目点击历史。训练好的扩散模型用于学习没有相应点击项目的查询的项目分布。顶部的 $K$ 个项目被视为对比学习的正样本, 旨在捕捉查询-项目关系。



### 2.1 Next Item Prediction

针对跨域兴趣转移问题, 作者设计了下一项预测模块。将 $t$ 时间以前的query序列通过自注意力层和FFN进行编码, 然后预测用户在推荐领域 $t + 1$ 时会点击的项目。我们期望引入的query表征可以更好地匹配用户在推荐领域中的兴趣, 理解用户在推荐领域中的偏好, 以提供更多信息。为此, 按照时间顺序映射推荐和搜索领域的交互记录, 并通过直接预测用户在推荐领域下一个可能点击的item, 来学习query的表征。

具体做法: 在推荐领域中, 从所有交互历史记录 $(u, i, y, t)$ 中, 构建两个item列表 $r_{u,t}^+$ 和 $r_{u,t}^-$ , 分别为用户 $u$ 在时间 $t$ 之后 $y = 1$  (有点击) 和 $y = 0$  (无点击) 的item列表。query序列 $q_u^t$ 由自注意力序列(SAS)编码成emb  $e_{q_u^t}$ 。使query emb与用户在推荐领域的点击物品 (正样本) 更接近, 而与未点击物品 (负样本) 更远离:

$$\mathcal{L}'_2 = -\frac{1}{|r_{u,t}^+|} \sum_{j \in r_{u,t}^+} \log \langle \mathbf{e}_{q_u^t}, \mathbf{e}_j \rangle - \frac{1}{|r_{u,t}^-|} \sum_{k \in r_{u,t}^-} \log(1 - \langle \mathbf{e}_{q_u^t}, \mathbf{e}_k \rangle)$$

其中 $\langle \cdot, \cdot \rangle$ 表示点积。为了更加高效，进行采样：

$$\mathcal{L}_2 = -\frac{1}{n_{\text{pos}}} \sum_{j \in r_{u,t}^+} \log \langle \mathbf{e}_{q_u^t}, \mathbf{e}_j \rangle - \frac{1}{n_{\text{neg}}} \sum_{k \in r_{u,t}^-} \log(1 - \langle \mathbf{e}_{q_u^t}, \mathbf{e}_k \rangle)$$

## 2.2 Diffusion-augmented Contrastive Learning

针对query与item表征对齐的问题，作者利用了对比loss，来学习query与item之间的相似性和差异性。将query和其相关的item对齐

### 1. query-item对比学习 (Contrastive Learning)

从搜索域的交互历史中，收集query $q$ 对应的正样本集，将其表示为 $\mathcal{I}_q^+$ 。其中，对于每个item $i \in \mathcal{I}_q^+$ ，至少有一位用户在通过 $q$ 搜索后， $i$ 曝光并且被点击。 $q^t$ 表示用户在 $t$ 时间之前的最后一次query。对比loss：

$$\mathcal{L}_3 = \frac{1}{|\mathcal{I}_q^+|} \sum_{i \in \mathcal{I}_q^+} \log \frac{\exp(s(\mathbf{e}_{q^t}, \mathbf{e}_i)/\beta)}{\sum_{j \in \mathbb{I} \setminus \mathcal{I}_q^+} \exp(s(\mathbf{e}_{q^t}, \mathbf{e}_j)/\beta)}$$

### 2. 基于Diffusion的数据增强 (Diffusion Data Augmentation)

搜索数据集的搜索点击记录稀疏，同时大部分的query没有正向互动的item，即对于大量的查询 $q$ ， $\mathcal{I}_q^+$ 为空，导致这些query在对比loss中没有标签。尽管如此，每个query都有一组未点击的item $\mathcal{I}_q^-$ ，对于item $i \in \mathcal{I}_q^-$ ，用户在通过 $q$ 搜索后， $i$ 曝光但是未被点击。可以将 $\mathcal{I}_q^-$ 用作对比信号，并使用Diffusion Model来增强被搜索点击的item $\mathcal{I}_q^+$



## 3 实验结果

在多个数据集上展示了所提出方法的有效性。

Dataset	KuaiSAR-small		KuaiSAR-large		Industrial	
Model	AUC	Imp %	AUC	Imp %	AUC	Imp %
DIN	0.6793	0	0.6892	0	0.8943	0
DCN	0.6729	-0.94	0.6749	-2.1	0.8948	0.02
PLE	0.6825	0.47	0.6879	-0.19	-	-
SESRec	0.6843	0.74	0.6859	-0.48	-	-
IV4REC+	0.6640	-2.25	0.6580	-4.53	-	-
QueryRec	0.6972	2.64	0.6996	1.5	0.8999	0.63

4 结论&想法

该paper的核心在于query表征的构建，提取推荐和搜索双域的信息，并将其融入到CTR模型中，实现知识从搜索领域到推荐领域的转移。这篇文章提出了一个关键问题：推荐域和搜索域之间由于用户消费意图和推荐曝光机制的差异，存在跨域兴趣转移。一方面，通过Next Item Prediction提取query特征，引入搜索后消费的正、负样本视频信息。在推荐域通过预测下一个，实现query表征与用户兴趣的对齐，使query表征具有推荐域的语义；另一方面，在搜索域通过对搜索行为历史emb结合对比学习、Diffusion进行优化，使其在搜索域的表达更加充分。基于此将推荐与搜索双域的信息都表征到query这一粒度。

更多技术细节请阅读原始论文。

欢迎干货投稿 \ 论文宣传 \ 合作交流

推荐阅读

RecSys2024 | 大序列推荐模型的扩展定律

AAAI2025 | 图解耦对比学习跨域推荐方法

WSDM2025推荐系统论文整理

由于公众号试行乱序推送，您可能不再准时收到机器学习与推荐算法的推送。为了第一时间收到本号的干货内容， 请将本号设为星标，以及常点文末右下角的“在看”。



喜欢的话点个在看吧

推荐系统干货分享 316

推荐系统干货分享 · 目录

上一篇  
论文周报[1223-1229] | 推荐系统领域最新研究进展(21篇)

下一篇  
论文周报[1230-0105] | 推荐系统领域最新研究进展(12篇)