AIGC算法工程师面经：NLP基础篇——文本解码超全总结

原创 喜欢卷卷的瓦力 瓦力算法学研所 2024年06月07日 09:09 广东

◈ 技术总结专栏 ◈

作者：vivida

瓦力算法学研所
我们是一个致力于分享人工智能、机器学习和数据科学方面理论与应用知识的公众号。我...
117篇原创内容

公众号

从分词、词表优化、词向量、词频、解码以及构建一个完整的文本分类模型讲解间NLP基础面试题。本篇主要讲解码部分。

本篇开始继续讲NLP基础，前面三期文章如下，没看过的小伙伴强烈推荐看一下~

AIGC算法工程师面经：NLP基础篇——从分词、词表优化、词向量、词频、解码到设计分类模型（一）
AIGC算法工程师面经：NLP基础篇——从分词、词表优化、词向量、词频、解码到设计分类模型（二）
AIGC算法工程师面经：NLP基础篇——从分词、词表优化、词向量、词频、解码到设计分类模型（三）

本系列将从分词、词表优化、词向量、词频、解码的理论和实践代码讲起，最终会将所有知识化零为整搭建一个完整的文本分类模型。

本篇主要讲解码部分。之前的面试题目只举例了Beam search 、Random sample策略，但由于文本解码涉及到的基础内容较多，本篇不严格按照面试问题来，会从概述、算法细节以及简单可上手的代码讲述。

下面是一个快捷目录。

一、前言

1. 文本解码

先用比较通俗的意思解释一下解码：

在生成文本结果的时候，模型的输出是一个时间步一个时间步依次获得的，而且前面时间步的结果还会影响后面时间步的结果。
也就是说，每一个时间步，模型给出的都是基于历史生成结果的条件概率。
那么解码就是：**为了生成完整的句子，融合模型多个时间步的输出，使得最终得到的序列的每一步条件概率连乘起来最大。**

2. 解码策略分类

文本生成中的decoding strategy主要可以分为两大类：

- Argmax Decoding: 主要包括beam search, class-factored softmax等
- Stochastic Decoding: 主要包括temperature sampling, top-k sampling等。

在生成模型中，最终会生成一个大小固定的hidden state hc；基于输入句子的hidden state hc 和先前生成的第1到t-1个词 $x1{:}t-1$；
Decoder会生成当前第t个词的hidden state ht ，最后通过softmax函数得到第t个词 xt 的vocabulary probability distribution $P(x|x1{:}t-1)$。

两类decoding strategy的主要区别就在于，如何从vocabulary probability distribution $P(x|x1{:}t-1)$ 中选取一个词 xt ：

- Argmax Decoding的做法是选择词表中probability最大的词，即$xt=argmaxP(x|x1{:}t-1)$；
- Stochastic Decoding则是基于概率分布$P(x|x1{:}t-1)$ 随机sample一个词 xt，即 $xt\sim P(x|x1{:}t-1)$ 。

在做seq predcition时，需要根据假设模型每个时刻softmax的输出概率来sample单词，合适的sample方法可能会获得更有效的结果。

二、贪婪采样（Argmax Decoding）

1. Greedy Search

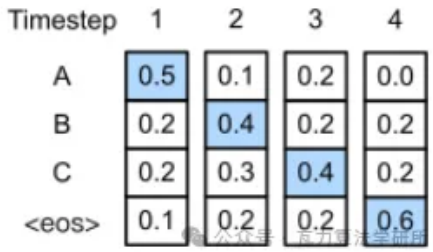

- **核心思想**

每一步取当前最大可能性的结果，作为最终结果。

- **具体方法**

获得新生成的词是vocab中各个词的概率，取argmax作为需要生成的词向量索引，继而生成后一个词。

2. Beam Search

- **核心思想**

beam search尝试在广度优先基础上进行进行搜索空间的优化（类似于剪枝）达到减少内存消耗的目的。

- **具体方法**

在decoding的每个步骤，都保留着 top K 个可能的候选单词，然后到了下一个步骤的时候，对这 K 个单词都做下一步 decoding，分别选出 top K，然后对这 K^2 个候选句子再挑选出 top K 个句子。以此类推一直到 decoding 结束为止。

- 举例

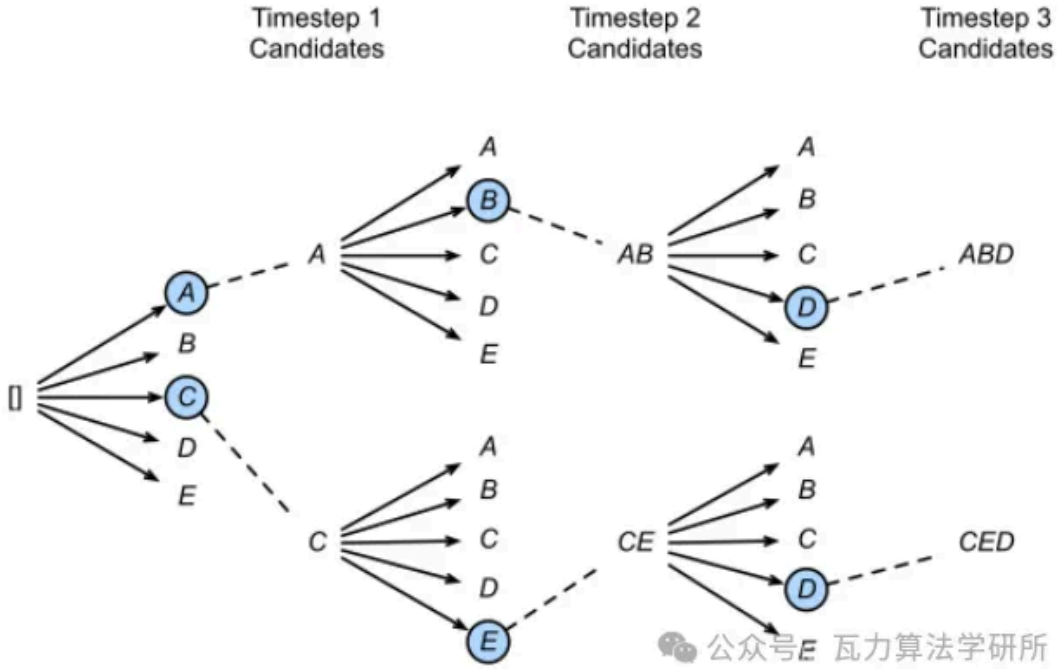

1）在第一个时间步，A和C是最优的两个，因此得到了两个结果[A],[C]，其他三个就被抛弃了；

2）第二步会基于这两个结果继续进行生成，在A这个分支可以得到5个候选，[AA],[AB],[AC],[AD],[AE]，C也同理得到5个，此时会对这10个进行统一排名，再保留最优的两个，即图中的[AB]和[CE]；

3）第三步同理，也会从新的10个候选里再保留最好的两个，最后得到了[ABD],[CED]两个结果。可以发现，beam search在每一步需要考察的候选数量是贪心搜索的num_beams倍，因此是一种牺牲时间换性能的方法。

3. Beam Search的优化

- 惩罚短句：Length normalization

Beam Search倾向于选择最短的句子，因为在这个连乘操作中，每个因子都是小于1的数，因子越多，最后的概率就越小。

解决这个问题的方法，最后的概率值除以这个生成序列的单词数，这样比较的就是每个单词的平均概率大小。此外，连乘因子较多时，可能会超过浮点数的最小值，可以考虑取对数来缓解这个问题。谷歌给的公式如下：

$$s(Y,X) = \log(P(Y|X))/lp(Y) + cp(X;Y)$$
$$lp(Y) = \frac{(5+|Y|)^\alpha}{(5+1)^\alpha}$$
$$cp(X;Y) = \beta * \sum_{i=1}^{|X|} \log(\min(\sum_{j=1}^{|Y|} p_{i,j}, 1.0)),$$

其中α∈[0,1]，谷歌建议取值为[0.6,0.7]之间，α用于length normalization。

- **Coverage normalization：惩罚重复**

序列到序列任务中经常会发现一个问题，2016 年， 华为诺亚方舟实验室的论文提到，机器翻译的时候会存在over translation or undertranslation due to attention coverage。

作者提出coverage-based atttention机制来解决coverage 问题。Google machine system 利用了如下的方式进行了length normalization 和 coverage penalty。

跟上述公式差不多，β用于控制coverage penalty

$$s(Y,X) = \log(P(Y|X))/lp(Y) + cp(X;Y)$$
$$lp(Y) = \frac{(5+|Y|)^\alpha}{(5+1)^\alpha}$$
$$cp(X;Y) = \beta * \sum_{i=1}^{|X|} \log(\min(\sum_{j=1}^{|Y|} p_{i,j}, 1.0)),$$

coverage penalty 主要用于使用 Attention 的场合，通过 coverage penalty 可以让 Decoder 均匀地关注于输入序列 X 的每一个 token，防止一些 token 获得过多的 Attention。

- **End of sentence normalization：抑制长句**

有的时候我们发现生成的序列一直生成下去不会停止，有的时候我们可以显式的设置最大生成长度进行控制，这里我们可以采用下式来进行约束：

$$ep(X,Y) = \gamma \frac{|X|}{|Y|}$$

其中|X| 是source的长度，|Y| 是当前target的长度，那么由上式可知，target长度越长的话，上述得分越低，这样就会防止出现生成一直不停止的情况。

4. 总结

Greedy Search和Beam Search存在的问题：

- 容易出现重复的、可预测的词；
- 句子/语言的连贯性差。

三、随机采样（Stochastic Decoding）

1. Temperature Sampling

- **核心思想**

根据单词的概率分布随机采样

- **具体方法**

在softmax中引入一个temperature来改变vocabulary probability distribution，使其更偏向high probability words：

$$P(x|x_{1:t-1}) = \frac{exp(u_t/temperature)}{\sum_{t'} exp(u_{t'}/temperature)}, temperature \in [0,1)$$

另一种表示：假设$p(x)$为模型输出的原始分布，给定一个 temperature 值，将按照下列方法对原始概率分布（即模型的 softmax 输出） 进行重新加权，计算得到一个新的概率分布。

$$\pi(x_k) = \frac{e^{log(p(x_k))/temperature}}{\sum_{i=1}^{n} e^{log(p(x_i))/temperature}}, temperature \in [0,1)$$

当$temperature \to 0$，就变成greedy search；当$temperature \to \infty$，就变成均匀采样（uniform sampling）。详见论文：[The Curious Case of Neural Text Degeneration]

2. Top-k Sampling

可以缓解生成罕见单词的问题。比如说，我们可以每次只在概率最高的50个单词中按照概率分布做采样。我只保留top-k个probability的单词，然后在这些单词中根据概率做sampling。

- **核心思想**

对概率进行降序排序，然后对第k个位置之后的概率转换为0。

- **具体方法**

在decoding过程中，从$P(x|x1{:}t-1)$ 中选取probability最高的前k个tokens，把它们的probability加总得到$p'=\sum P(x|x1{:}t-1)$；

然后将 $P(x|x1{:}t-1)$ 调整为 $P'(x|x1{:}t-1)=P(x|x1{:}t-1)/p'$ ，其中 $x \in V(k)$!；

最后从 $P'(x|x1{:}t-1)$ 中sample一个token作为output token。详见论文：[Hierarchical Neural Story Generation]

- **存在的问题**

Top-k Sampling存在的主要问题是，**k不太好选**：

常数k是提前给定的值，对于长短大小不一，语境不同的句子，可能有时需要比k更多的tokens；

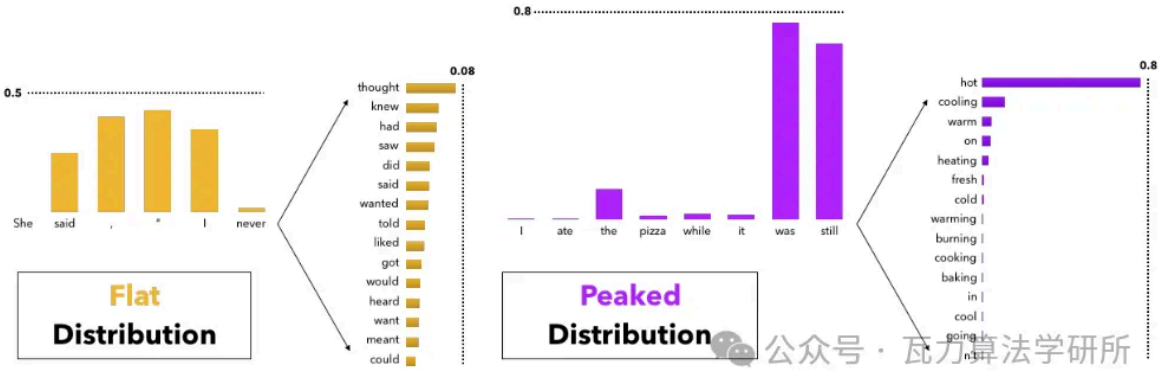

此外，因为这个概率分布变化比较大，有时候可能很均匀(flat)，有的时候比较集中(peaked)。对于集中的情况还好说，当分布均匀时，一个较小的k容易丢掉很多优质候选词。但如果k定的太大，这个方法又会退化回普通采样。

3. top-p sampling（ Nucleus Sampling ）

- **核心思想**

通过对概率分布进行累加，然后当累加的值超过设定的阈值p，则对之后的概率进行置0。

- **具体方法**

提出了Top-p Sampling来解决Top-k Sampling的问题，基于Top-k Sampling，它将 $p'=\sum P(x|x1{:}t-1)$ 设为一个提前定义好的常数$p'\in(0,1)$，而selected tokens根据句子history distribution的变化而有所不同。

详见论文：[The Curious Case of Neural Text Degeneration]

论文有一个效果对比图，对比了这几种采样方式的效果。红字是前后不符，蓝字是重复。Nucleus效果拔群。

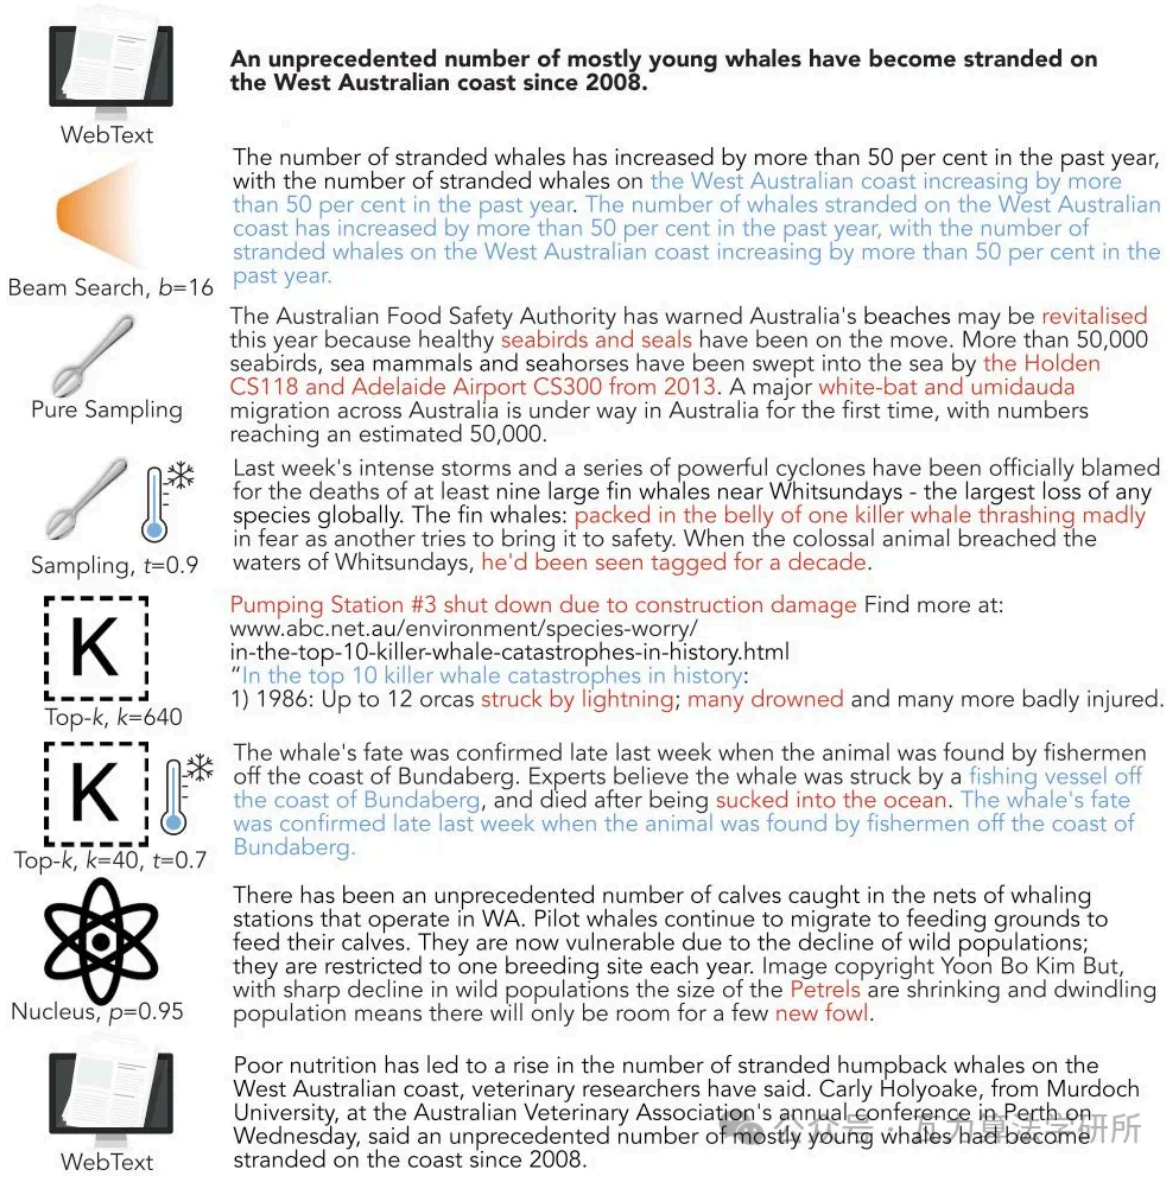

本质上Top-p Sampling和Top-k Sampling都是从truncated vocabulary distribution中sample token，区别在于置信区间的选择。

4. 总结

随机采样存在的问题：

- 生成的句子容易不连贯，上下文比较矛盾。
- 容易生成奇怪的句子，出现罕见词。

四、手撕beam search代码

下面我们来写一个基础版本的beam search函数，由于大部分提供的库写得比较复杂，涉及Beam类以及其中各个 score函数、extend函数，但实际面试过程中可能没法这么写，因此这里总结一个简便又便于理解的版本。

详细步骤如下：

1. 初始化Result列表用来存储每次得到的最大k个概率结果，初始化为[[list(),1]] 1为当前初始化的成绩
2. 遍历最大解码长度S（解码出来S个字），
3. 编历Result，用来为每个当前为止的最大k个结果解码出候选集
4. 每个解码出的k个结果统一存储在Condidate列表中
5. 按照成绩选取前k个作为Result，继续遍历，直到解码出S长度或者<eos>

代码如下

```
from math import log
from numpy import array
from numpy import argmax

# 集束搜索
def beam_search_decoder(data, k):
  sequences = [[list(), 1.0]]#初始化存储最后结果的列表，存储k个
  # 遍历序列中的每一步
  for row in data:#序列的最大长度
    all_candidates = list()
    # 扩展每个候选项，即解码当前所得序列的下一个字
    for i in range(len(sequences)):
      seq, score = sequences[i]
      for j in range(len(row)):#计算每个词表中的字的成绩
        candidate = [seq + [j], score * -log(row[j])]
        all_candidates.append(candidate)
    # 根据分数排列所有候选项
    ordered = sorted(all_candidates, key=lambda tup:tup[1])
    # 选择k个最有可能的
    sequences = ordered[:k]
  return sequences

# 定义一个由10个单词组成的序列，单词来自于大小为5的词汇表
data = [[0.1, 0.2, 0.3, 0.4, 0.5],
    [0.5, 0.4, 0.3, 0.2, 0.1],
    [0.1, 0.2, 0.3, 0.4, 0.5],
    [0.5, 0.4, 0.3, 0.2, 0.1],
    [0.1, 0.2, 0.3, 0.4, 0.5],
    [0.5, 0.4, 0.3, 0.2, 0.1],
    [0.1, 0.2, 0.3, 0.4, 0.5],
    [0.5, 0.4, 0.3, 0.2, 0.1],
    [0.1, 0.2, 0.3, 0.4, 0.5],
    [0.5, 0.4, 0.3, 0.2, 0.1]]
data = array(data)
```

```
# 解码输出序列
result = beam_search_decoder(data, 3)
# 打印结果

for seq in result:
  print(seq)
```

另外的大模型常用的解码代码也可以参考大模型面经之解码策略topk、topp（附代码）这篇。

参考文献

[1] 《Python深度学习》第8章第1节：8.1 使用LSTM生成文本P228-P234。

[2] The Curious Case of Neural Text Degeneration: [https://arxiv.org/abs/1904.09751]

[3] CTRL: A Conditional Transformer Language Model for Controllable Generation: [https://arxiv.org/abs/1909.05858]

[4] The Curious Case of Neural Text Degeneration [https://arxiv.org/abs/1904.09751]

[5] Hierarchical Neural Story Generation [https://arxiv.org/abs/1805.04833]

想要获取技术资料的同学欢迎关注公众号，进群一起交流~

瓦力算法学研所
我们是一个致力于分享人工智能、机器学习和数据科学方面理论与应用知识的公众号。我...
117篇原创内容

公众号