超全版本AIGC算法工程师面经总结,建议收藏

原创 喜欢卷卷的瓦力 瓦力算法学研所 2024年05月22日 16:09 广东

◇ 面试经验专栏 ◇

作者: vivida



瓦力算法学研所

我们是一个致力于分享人工智能、机器学习和数据科学方面理论与应用知识的公众号。我... 117篇原创内容

公众号

AIGC算法工程师面试经验复习大纲总结。

自openai发布Sora、chatGPT等一系列重磅产品,相关新闻持续刷屏,国内aigc产品以及相关岗位的机会、工资也越来越可观。

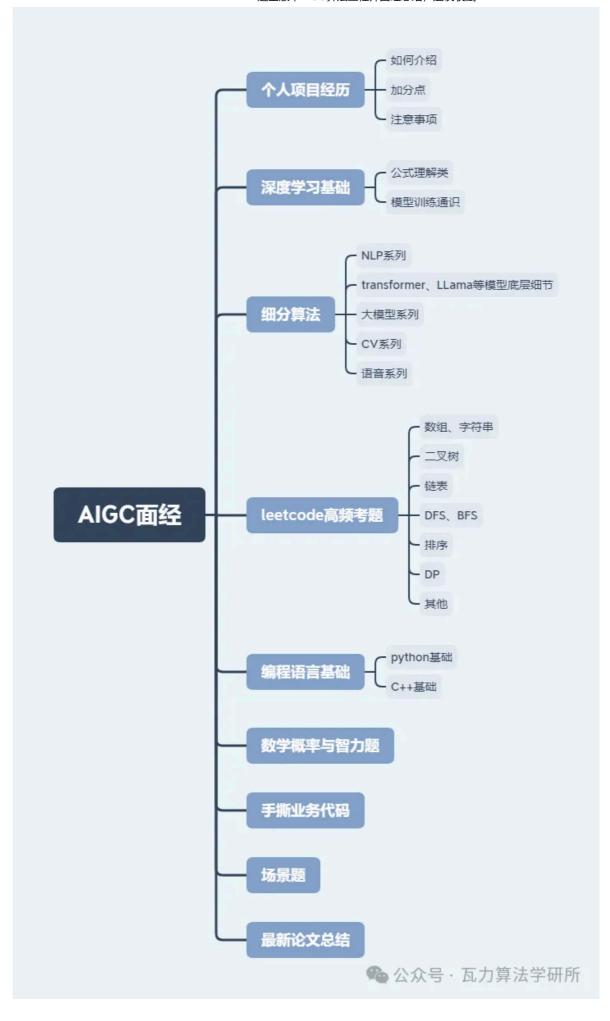
本篇为来自各大厂从业者等业内人士做的免费面经总结,希望能为想进入或者即将入行这一领域的小伙伴提供一些有益的参考和指导!超强干货!建议收藏!

那么目前算法工程师面试将会考一些什么问题? 笔者作为面试官,对基本会遇到的问题做一个比较全面的总结,附上问题与对应答案,直接上干货。

本篇会概述项目经历、深度学习基础、各细分算法(NLP、CV、大模型等)、前沿算法论文了解、leetcode算法基础、python及C++语言基础、数学概率及智力题、手撕代码以及场景题等...

下面是一个快捷目录。

由于相关内容过多,本文只列举大纲与部分已发布的详细问题,更多内容与答案会陆续发出,最终会总结出免费pdf方便大家复习,欢迎大家关注公众号获取。



一、个人项目经历

对于所有的相关经历,都是跟面试官聊技术的切入点,大家一定要进行详细的准备,具体的注意点如下:

1.1 如何介绍

从数据规模、特征、指标、目前使用的模型方法、项目难点详细介绍

1.2 加分点

自己的思考、学习、成长

一定要明确地说出自己做的项目亮点! 一定要仔细地思考, 业务考虑得够广, 技术考虑得够深。

1.3 注意事项

不要只描述业务,用到了这个岗位对应到的哪些技术,从自己的能力、自己设计的方案出发。 **用到的技术一定要详细准备。**

二、深度学习基础

2.1 公式理解类

在实际面试中,这类问题很大概率需要手写,或者需要很清晰地讲出公式含义及原理,这个过程中可能会遭到反复拷打,甚至手撕代码。

这里做一个部分面试问题总结,并将整理资料放在下方,大家可以具体点击来看。

- 手写softmax公式, 手写BN公式, softmax层的label是什么
- 手写交叉熵公式, 分类为什么用交叉熵不用平方差
- 手写知识蒸馏公式
- 手写NER损失函数
- 为什么逻辑回归用sigmoid激活函数? 多分类逻辑回归是否也是sigmoid?
- 手推lr梯度, 交叉熵损失为什么有log项? 为什么取负

AIGC算法工程师面经—公式理解篇(上)

AIGC算法工程师面经—公式理解篇(下)

2.2 模型训练通识

.....

模型训练通识类题目,此类宽泛的问题类似于命题作文,看似简单且答案明确,但实际考量的空间非常大;单纯地背完八股面试官往往是不满意的,一般的反应是再问更细节的内容或者直接反馈觉得你还说的不够。

这种时候最好要结合一些自身的实践经验,或者将题目与答案说得更深一些。

这里做一个部分的面试问题总结,并将整理资料放在下方。

• 介绍一下L1、L2正则化 L1 为啥能得到稀疏

- 激活函数的优缺点: sigmoid、tanh、relu、gel
- 如何处理数据不平衡问题
- 训练中学习率调整策略是怎样的
- 介绍一些神经网络初始化的一些方法
- 有哪些归一化方案

•••••

AIGC算法工程师面经——模型训练通识基础篇

三、细分算法

3.1 NLP系列

NLP系列问题还是需要结合项目经历,尽量把自己项目中涉及到的技术讲透彻。

- 训练时词表大小过大,输出层过大的优化方法
- 如何优化Muti-Head的计算?
- 注意力机制有哪些种类,本身原理上起了什么作用
- CNN、RNN、Transformer分别怎么编码文本
- embedding方式有哪些

....

这里做一个部分的面试问题总结,并将整理资料放在下方,后续会持续完善。

AIGC算法工程师面经: NLP基础篇——从分词、词表优化、词向量、词频、解码到设计分类模型 (一)

AIGC算法工程师面经: NLP基础篇——从分词、词表优化、词向量、词频、解码到设计分类模型(二)

3.2 transformer 细节

- 为什么transformer用Layer Norm? 有什么用?
- transformer为什么要用三个不一样的QKV?
- Bert中为什么要在开头加个[CLS]?
- Bert中有哪些地方用到了mask?
- Bert为什么要使用warmup的学习率trick

•••••

大模型面经-transformer部分-附答案

3.3 大模型系列

大模型系列目前涉及到的岗位和内容应用实际是非常多的,所以除了简单的问题罗列,这里做了一个大致的学习路线分类,后续会持续完善这块版图。

目前针对大模型的单个岗位会结合场景去靠,除了文本,还需要考虑图像embedding、数值、逻辑推理类型的数据用于指令微调时更深度的用法。

此外具体对应到的哪些技术,要从自己的能力、自己设计的方案出发;场景中用到的技术一定要详细准备。

对这块感兴趣的小伙伴欢迎加群一起讨论,大家一起总结。

- 介绍一下常见大模型结构: gpt、bart、t5等
- in-context learning和传统finetune的区别
- prompt-tuning和prefix-tuning的区别,各自的优缺点
- 解释一下大模型的位置编码 (rope等)
- 介绍一下gpt的训练流程
- MoE的原理

.....



■ 3.1.1 基础

。 大模型设计思路

NLP大语言模型设计的思考笔记 (一)

NLP大语言模型设计的思考笔记(二)

。 大模型基础结构

大模型面经——从prefix-decoder、casual-decoder、encoder-decoder角度深入聊聊大模型

•••••

■ 3.1.2 进阶

。 大模型学术理论细节

为什么现在的LLM都是Decoder-only架构?从理论、训练效率与工程实现等多维度分析现在LLM的大小为什么都设计成6/7B、13B和130B几个档次?解析大模型中的Scaling Law大模型LLM为什么要用旋转位置编码(RoPE)--解析位置编码的前世今生大语言模型LLM为什么要用旋转位置编码(RoPE)——被LLaMA认可的长文本外推性(附代码)如何提升transformer架构下LLM的长序列学习能力?解析大模型中的长序列学习原理复旦MOSS团队:数据配比的scalinglaw

大模型面经——LLama2和chatGLM相对于transformer具体做了哪些优化? 大模型面经——大模型中用到的归一化方法总结

。 强化学习

大模型面经答案—强化学习: 理论解释与讲解 大模型面经—强化学习实践经验与思考阐释 大模型强化学习RLHF在实践过程中存在的不足及其解决方案是什么? 有没有一些最新的替代方案? 大模型强化学习实操(一)——如何训练一个自己偏好的大模型(附代码)

。 知识蒸馏与量化

大模型目前量化方法有哪些? 详细介绍实际落地中最常用方法

○ 多模态

聊聊SORA背后技术之一: Stable Diffusion 聊聊SORA背后技术之一(二): CLIP 聊聊SORA背后技术之一(三): VAE

■ 3.1.3 实践

。 训练技巧

垂直领域大模型微调实践经验最全总结 大模型面经——超细节大模型训练与微调实操经验总结(上) 大模型面经——大模型训练中超参数的设置与训练数据偏好

○ 微调经验

大模型微调实践——Prompt tuning、PET、Prefix tuning、P-tuning的原理、区别与代码解析(一) 大模型微调实践——Prompt tuning、PET、Prefix tuning、P-tuning的原理、区别与代码解析(二) 大模型微调实践——Prefix tuning与P-tuning v2的原理、区别与代码解析最终章

3.1.4 推理

○ 推理加速

大模型面经之解码策略topk、topp(附代码) 大模型微调实践经验——生成/推理中参数与解码策略原理及其代码实现 大模型面经之什么是大模型复读

•••••

3.1.5 优化

。 幻觉问题优化

大模型的幻觉问题 控制大模型幻觉也太难了吧

。 RAG检索生成

∘ MoE

火爆AI社区的混合专家模型 MoE到底是什么?来实测一下MoE算法效果

•••••

3.1.6 应用

Agent

大模型面经之Agent介绍 大模型面经之Agent介绍(二)

Langchain

•••••

3.4 CV系列

- 图像Resize前后,是否应该保持宽高比例一致?图像内容变形是否对模型效果有影响?(padding和 resize之间的差异什么?)
- 图像的数据增强有哪些方法?
- 不同的卷积核、不同的卷积方式有哪些?
- yolov1-yolov8各个模型的改进方式有哪些?
- stable diffusion原理介绍?

•••••

视觉面经之小目标检测篇

视觉面经之归一化篇

视觉面经之目标检测回归损失篇 (IOU、GIOU、DIOU、CIOU)

3.5 语音系列

语音这一块其实目前相对招的岗位是最少的,跟大模型的结合应用相对来说也比较独立。

- 语音合成中如何让声音更人性化, 举例1个技术方案
- mfcc特征的提取过程
- mfcc特征与fbank的区别
- 端到端模型与传统模型的区别
- 如何理解强制对齐?

• • • • • • •

四、leetcode高频考题

对于AIGC算法工程师来说,一般考二叉树、排序、动规、数组都比较多,除非是大模型部署类岗位, 考堆和栈相对较少。

下面总结一些必备的高频考题,欢迎大家一起进群补充。

4.1 数组

- 正整数组中寻找连续区间使得和等于target
- 顺时针打印数组
- 找到所有数组中消失的数字
- 从两个有序 (从大到小) 数组中选出最大的k个数
- 寻找数组中是否存在超过一半的数字
- 求数组中第k大的数
- 找出数组中a+b=c的组合,其中abc都在数组里,时间空间复杂度
- 升序倒序数组找 target
- 给定一个目标值M的数组,返回数组是否存在和为M子集
- 查找有序数组特定元素
- 给定一个数组和一个整数k,判断数组能否被分为多个和为k的子数组
- 给定一个数组,拼接一个最大的数
- 有序含重复值数组找某个值第一次出现的位置

4.2 二叉树

- 无序数组转二叉搜索树
- 两个树节点的最近公共祖先
- 二叉树先序遍历展开成链表 in-place
- 无序数组转平衡二叉搜索树 (不能先对数组进行排序)
- 给你两颗二叉树 a,b(只有数的结构而没有 value),判断a 是否 b 的子树(只需要 b 的某个子树结构跟 a 一样就行),能否继续优化?
- 二叉树直径, LeetCode 543

4.3 链表

- 链表翻转
- 合并两个有序链表
- 判断链表是否有环,返回环的入口

• 判断两个链表是否相交

4.4 DFS, BFS

- 打印字符串所有子序列
- 字符串全排列 (字符串可能有重复元素)
- 迷宫问题,迷宫里有多个人处于不同位置,每个人逃出迷宫有最短路径值,求这些最短路径值的最大值
- 划分为 k 个相等的子集:给定一个整数数组 nums 和一个正整数 k,找出是否有可能把这个数组分成 k 个非空子集,其总和都相等

4.5 排序

- 子数组最大和
- 子矩阵和的最大值
- 两个有序数组的中位数
- 求数组的第 k 大数, 时间复杂度是多少?
- 读取文本,统计,然后排序(有多个排序因素)
- 一个数组只包含0,1,2三个数,对这个数组进行排序
- 最大数组合: 给定一个非负整数数组, 求一个拼接出来的最大数。比如 [2, 32] => 322

4.6 DP

- 股票最大利润(只能交易一次)
- 走楼梯方法数,一次可以走一个台阶或者两个台阶,总共有 n 个台阶
- 01数组,长度为 n, 1代表可达, 0 代表不可到达, 一次可以跳 3 到 5 步。求跨越该数组的最小步数 (起点可以看成 index 为 -1, 终点可以看成 index 为 n)
- 硬币兑换最小数

4.7 其他

- 0~4随机函数,怎么生成0~6的随机函数
- Top-K问题, 手写堆调整 +1

五、编程语言基础

5.1 python基础

- 怎么优化内存管理
- 线程直接如何进行资源共享
- Python 列表合并方法有哪些
- Python copy 和 deepcopy 区别, if a 和 if a is not None 区别
- Python is 和 == 区别,两者分别在比较什么?
- python装饰器与生成器

AIGC算法工程师面经—python基础篇

5.2 C++

- C/C++中内存泄漏以及解决方法?
- C/C++中野指针的概念
- C/C++中常用容器功能汇总
- C/C++中指针和引用的区别

六、数学概率与智力题

本章基本要尽量往概率论方向上复习准备,考题一般会出的比较简单,需要从极大似然或者用动规的方法去思考。

- x, y服从0-1均匀分布, 求x+y<1的概率? x, y, z服从0-1均匀分布, 求x+y+z<1的概率?
- 考虑五局三胜和三局两胜,哪种更公平(中心极限定理)
- 10个袋子,1000个球,用球填充袋子,然后固定。现在有一个客户,无论要1~1000那个数量,都 能通过袋子组装给他(动态规划)
- 抛硬币一亿次都是正面,下一次是反面的概率有多大, (最大似然)
- N枚真硬币是一面图案一面字,M枚假硬币是两面图案,选了一枚抛K次都是图案,问是真硬币的概率——贝叶斯
- 25匹马, 5个赛道, 最多几次可以知道前三名

七、手撕代码

- 实现一下求编辑距离
- 固定参数训练代码怎么写
- 用Pytorth实现一个2层的感知机二分类器。需要实现基本功能,包括:定义输入、网络结构、batch 的loss、acc、预测结果的label,预测结果的概率分布等

八、场景题

- 年龄预测(范围 10 到 50),目标是最大化准确率,怎么设计损失函数?如果要求预测结果在正负 3以内就行,怎么设计损失函数,如何优化?
- 怎么给 50 w 高考考生成绩排序, 要求时间空间复杂度尽可能低
- 有一款新游戏, 怎么识别出土豪 (可能在新游里充大量钱的用户)
- 提供一个包含所有英文单词的字典,为手机的T9输入法设计一个索引,例如输入4能够提示出g、h、i开头的英文单词(greate、hello、......),输入43能够提示出ge、he、id、if (hello......) 等词开通的英文单词
- 给一个训练样本,其中有一个离散特征,取值有100W维,怎么解决
- 从海量数据中寻找频数前1000的数据
- 多分类如果有 10000 类别, 怎么优化

九、最新论文总结

- 现在一般用什么方法替代强化学习? (DPO)
- 详细讲一下最新看过的论文并评价
- 解析一下sora可能用了哪些技术
- 讲讲llava系列中你最感兴趣的技术

•••••

写在最后,本文中的问题只是抛砖引玉,具体的答案与内容还会持续更新与扩充,最终方便大家复习的 pdf版本目前还在整理中,欢迎大家关注公众号获取。

欢迎各位想进入AIGC的小伙伴进群一起讨论交流面试以及大模型训练、应用的经验~



添加瓦力微信

算法交流群·面试群大咖分享·学习打卡

♣ 公众号·瓦力算法学研所



瓦力算法学研所

我们是一个致力于分享人工智能、机器学习和数据科学方面理论与应用知识的公众号。我... 117篇原创内容

公众号

面试干货 70

面试干货:目录

上一篇

下一篇

大模型面经之Agent介绍(二)

大模型面经——大模型训练中出现loss突刺的原因和解决方法详解